

MBA EM **DATA SCIENCE E ANALYTICS**

Engenharia de Dados I

Guilherme Lima

Larissa Dos Santos Magistrali 867.843.400-78

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.


Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Larissa Dos Santos Magistral 867.843.400-78

MBAUSP
ESALQ





O que é engenharia de dados?




Google

Google Search

I'm Feeling Lucky

Engenharia de dados




A engenharia de dados é a área responsável pelo desenvolvimento e manutenção de sistemas que coletam, organizam, e processam dados.


Engenharia de dados

Construir a base para a ciência de dados





Ciclo de vida dos *dados*






ETL - Extração, Transformação, Carregamento



Extração

Coleta dados de diferentes fontes



Transformação


Dos dados para atender às necessidades



Carregamento

Carregamento dos dados

Annual Size of the Global Datasphere



Engenharia de dados tem tudo a ver com movimentação, manipulação e gerenciamento de dados.

1998

John R. Mashey

"Big data"

Definir o crescimento do armazenamento
e da produção de dados





2001

Doug Laney

3Vs

1. Volume
2. velocidade
3. variedade

Desafio

Larissa Dos Santos Magistrali 867.843.400-78

Desafio

Você é um cientista de dados de uma loja online de roupas. Sua missão é prever qual linha de roupas um cliente comprará em seguida. Antes de construir o modelo, você precisa preparar os dados corretos.

Desafio

Liste pelo menos 5 tipos de dados que você acredita serem úteis para prever a próxima compra do cliente.

Larissa Dos Santos Magistrali 8611843.400-78

Desafio

Cite 3 possíveis problemas que você encontraria ao preparar esses dados.

Larissa Dos Santos Magistral 867.843.400-78

Desafio


Imagine que 80% do seu tempo será gasto só preparando os dados – limpando, juntando tabelas, tratando valores nulos, criando variáveis úteis (engenharia de recursos) – sobrando apenas 20% para criar e melhorar o modelo.

Solução


Ter um engenheiro de dados na equipe!
Ele automatiza a coleta, limpeza, transformação e preparação dos dados, revertendo a divisão de tempo e deixando você livre para focar no modelo.

Armazenar dados em seu local de destino





90-00s



YAHOO!

Google


amazon

2000



2000

BIG DATA



Uma nova fase estava começando



Conjuntos de dados extremamente grandes que podem ser analisados computacionalmente para revelar padrões, tendências e associações, especialmente relacionadas ao comportamento e às interações humanas



2003

The Google File System.

Ghemawat03: S. Ghemawat, H. Gobioff,
S-T. Leung, Symp. on Operating Systems
Principles (SOSP'03), Oct 2003, Bolton
Landing, NY.

YAHOO!

2006



amazon

2006




Qual a diferença?



Engenheiro de Dados

VS



Cientista de Dados

O que geralmente o engenheiro de dados não faz...

- Criar modelos de Machine Learning (ML)
- Elaborar relatórios ou dashboards
- Realizar análises de dados
- Criar indicadores-chave de desempenho (KPIs)
- Desenvolver aplicativos de software





Níveis de maturidade dos dados


Desafio

Larissa Dos Santos Magistrali 867.843.400-78

Desafio

Você foi contratado como Engenheiro de Dados em uma startup que acabou de decidir usar MySQL para centralizar seus dados. Sua primeira tarefa é simples, mas crucial: instalar no seu computador para começar a criar os bancos de dados da empresa.







O primeiro passo da engenharia
de dados é focada em
Structured Query Language




Os dados são armazenados e processados em bancos de dados relacionais.

ORACLE®



Microsoft®
SQL Server®



PostgreSQL



O que são banco de dados relacionais?



São sistemas de armazenamento de dados onde as informações ficam organizadas em **tabelas** (linhas e **colunas**) que se relacionam entre si.

(Por isso o nome: "relacionais".)



Criar um novo banco de dados

```
CREATE DATABASE nome_do_banco;
```



Seleciona qual banco de dados você vai usar

```
USE nome_do_banco;
```



Cria uma nova tabela

```
CREATE TABLE clientes (  
    id INT PRIMARY KEY AUTO_INCREMENT,  
    nome VARCHAR(100),  
    email VARCHAR(100)  
);
```



Inserir dados na tabela clientes

```
INSERT INTO clientes (nome, email) VALUES  
( 'João', 'joao@email.com' );
```

Larissa Dos Santos Magistral 867.842.400-78



Consulta dados da tabela.

```
SELECT * FROM clientes;
```

Larissa Dos Santos Magistrali 867843.400-78

Atualiza dados já existentes.

```
UPDATE clientes SET email = 'joao@gmail.com' WHERE id = 1;
```



Remove registros da tabela.

```
DELETE FROM clientes WHERE id = 1;
```



Obrigado!

Guilherme Lima | [linkedin](#)

MBAUSP
ESALQ