

MBA EM **DATA SCIENCE
E ANALYTICS**

Unsupervised Machine Learning: Clustering

Prof. Dr. Wilson Tarantin Junior

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.


Lei nº 9610/98

Larissa Dos Santos Magistral 867.843.400-78

Contextualização

- Quando aplicar a análise de cluster?
 - Quando o objetivo for **agrupar as observações** em grupos homogêneos internamente e heterogêneos entre si
- Portanto, espera-se obter:
 - **Dentro do grupo:** observações semelhantes com base nas variáveis utilizadas
 - **Entre grupos distintos:** observações diferentes com base nas variáveis utilizadas

Contextualização



Contextualização

- Exemplos de aplicação
 - Segmentação de clientes para marketing
 - Análises socioeconômicas e demográficas de regiões
 - Detecção de fraudes em transações (transações atípicas)
 - Controle de qualidade no processo produtivo
 - Identificação de grupos de pacientes para prevenção de doenças
 - ...

Contextualização

- Técnica exploratória (não supervisionada)
 - A análise de cluster busca identificar o padrão latente de agrupamento presente nos dados: não há a especificação prévia de quais grupos devem ser formados
 - Técnica exploratória: não tem caráter preditivo para observações de fora da amostra
 - Se observações forem adicionadas/retiradas da amostra, novo agrupamento deve ser formado, pois a mudança de observações pode alterar a composição dos grupos
 - Se forem alteradas as variáveis da análise, novo agrupamento deve ser realizado, porque a inclusão/retirada de variáveis pode alterar a composição dos grupos

Métodos

- Analisaremos dois métodos para a obtenção de agrupamentos
 - **Método Hierárquico Aglomerativo**
 - A quantidade de clusters é definida ao longo da análise (passo a passo)
 - É um método mais analítico e com característica bastante exploratória
 - **Método Não Hierárquico K-means**
 - Define-se a priori quantos cluster serão formados
 - É um método mais objetivo, pois baseia-se em minimização

Método Hierárquico Aglomerativo

Larissa Dos Santos Magistrali 867.843.400-78

Tratamento inicial dos dados

- Análise das variáveis que serão estudadas
 - Antes de iniciar os procedimentos, é importante realizar uma análise das unidades de medidas das variáveis
 - Se estiverem em unidades de medidas distintas, é importante realizar a padronização das variáveis antes de iniciar a análise de cluster
 - Aplica-se o ZScore (torna variáveis com média = 0 e desvio padrão = 1)

$$ZX_{ji} = \frac{X_{ji} - \bar{X}_j}{s_j} \left\{ \begin{array}{l} \bar{X}_j \text{ é a média da variável } j \\ s_j \text{ é o desvio padrão da variável } j \end{array} \right.$$


Escolhas inerentes ao método

- A análise de cluster hierárquica depende de escolhas
 - Escolha da medida de dissimilaridade (distância)
 - Refere-se à distância entre as observações, com base nas variáveis escolhidas
 - Portanto, indica o quanto as observações são diferentes entre si
 - Escolha do método de encadeamento das observações
 - Refere-se à especificação da medida de distância quando houver cluster formados

Esquema de aglomeração

- **Hierárquico aglomerativo:** observações separadas → um único cluster
 - Considerando n observações na amostra, inicia-se com n clusters (estágio 0)
 - Na sequência, une-se as duas observações com **menor distância** ($n - 1$ clusters)
 - Em seguida, um novo grupo é formado pela união de duas novas observações ou pela inclusão de uma observação ao cluster formado na etapa anterior (**sempre pela menor distância**). **O método de encadeamento indica qual é a distância a ser considerada**
 - Repete-se a etapa anterior $n - 1$ vezes até restar 1 cluster com todas as observações
 - O **dendrograma** é o gráfico que permite visualizar a formação dos clusters

Exemplo de dendrograma



Medidas de dissimilaridade

- Identifica a distância entre observações

- Distância euclidiana: $d_{pq} = \sqrt{\sum_{j=1}^k (ZX_{jp} - ZX_{jq})^2}$

- Distância euclidiana quadrática: $d_{pq} = \sum_{j=1}^k (ZX_{jp} - ZX_{jq})^2$

- Distância de Manhattan (City Block): $d_{pq} = \sum_{j=1}^k |ZX_{jp} - ZX_{jq}|$


Medidas de dissimilaridade

- Identifica a distância entre observações
 - Distância de Chebychev: $d_{pq} = \max |ZX_{jp} - ZX_{jq}|$
 - Distância de Canberra: $d_{pq} = \sum_{j=1}^k \frac{|ZX_{jp} - ZX_{jq}|}{|ZX_{jp}| + |ZX_{jq}|}$
 - A correlação de Pearson entre as observações também pode ser utilizada (mas é uma medida de semelhança, portanto, ajusta-se sua interpretação antes de usá-la)

Métodos de encadeamento

- Identifica qual distância utilizar quando já existem clusters formados durante os estágios aglomerativos
 - ***Nearest neighbor (single linkage)***: privilegia menores distâncias, recomendável em casos de observações distintas
 - ***Furthest neighbor (complete linkage)***: privilegia maiores distâncias, recomendável em casos de observações parecidas
 - ***Between groups (average linkage)***: junção de grupos pela distância média entre todos os pares de observações do grupo em análise

Métodos de encadeamento

Método de Encadeamento	Ilustração	Distância (Dissimilaridade)
Único (Nearest Neighbor ou Single Linkage)		d_{23}
Completo (Furthest Neighbor ou Complete Linkage)		d_{15}
Médio (Between Groups ou Average Linkage)		$\frac{d_{13} + d_{14} + d_{15} + d_{23} + d_{24} + d_{25}}{6}$

Fonte: Fávero & Belfiore (2024, Capítulo 9)

Métodos de encadeamento

- Esquemas hierárquicos aglomerativos
 - Nearest neighbor (single linkage): vizinho mais próximo
 - $d(MN)W = \text{mínimo}\{dMW ; dNW\}$
 - Furthest neighbor (complete linkage): vizinho mais distante
 - $d(MN)W = \text{máximo}\{dMW ; dNW\}$
 - Between groups (average linkage): média das distâncias
 - $d(MN)W = \text{média}\{dMW ; dNW\}$

Quantos clusters escolher?

- Esquemas hierárquicos aglomerativos
 - Como critério para a escolha do número final de clusters em uma análise hierárquica pode-se adotar o tamanho dos saltos de distância para a aglomeração (com base no dendrograma)
 - Saltos elevados podem indicar o agrupamento de observações com características diferentes, isto é, há a união de observações mais distintas
 - Muitas vezes, é importante comparar dendrogramas obtidos por diferentes métodos de encadeamento

Análise dos agrupamentos

- Quais variáveis contribuem?
- Após a clusterização, é importante comparar se a variabilidade dentro do grupo é menor do que a variabilidade entre grupos com base nas variáveis da análise
- Aplica-se um teste F para análise de variância: $F = \frac{\text{Variabilidade entre grupos}}{\text{Variabilidade dentro dos grupos}}$
 - Graus de liberdade no numerador: $K - 1$
 - Graus de liberdade no denominador: $n - K$
- É possível analisar quais variáveis mais contribuíram para a formação de pelo menos um dos clusters: maiores valores da estatística F (em conjunto com sua significância)

$K = \text{n}^\circ \text{ de clusters}$
 $n = \text{tamanho da amostra}$

Método Não Hierárquico K-means

Larissa Dos Santos Magistrali 867.843.400-78

Tratamento inicial dos dados

- Análise das variáveis que serão estudadas
 - Antes de iniciar os procedimentos, é importante realizar uma análise das unidades de medidas das variáveis
 - Se estiverem em unidades de medidas distintas, é importante realizar a padronização das variáveis antes de iniciar a análise de cluster
 - Aplica-se o ZScore (torna variáveis com média = 0 e desvio padrão = 1)

$$ZX_{ji} = \frac{X_{ji} - \bar{X}_j}{s_j} \left\{ \begin{array}{l} \bar{X}_j \text{ é a média da variável } j \\ s_j \text{ é o desvio padrão da variável } j \end{array} \right.$$

Esquemas de aglomeração


- Esquema não hierárquico K-means
 - **A quantidade (K) de clusters deve ser escolhida a priori** e é utilizada como base para a identificação dos centros de aglomeração (centroides)
 - Os K centroides iniciais são determinados aleatoriamente; as observações são alocadas aos clusters iniciais com base no centroide mais próximo
 - Após o agrupamento inicial, recalcula-se o valor de cada centroide com base na média dos pontos de cada grupo
 - Ao recalcular o valor do centroide, as observações podem mudar de cluster se estiverem mais próximas de outro centroide. Torna-se um processo iterativo...

Esquemas de aglomeração

- Esquema não hierárquico K-means
 - O processo K-means encerra-se quando não for possível realocar qualquer observação por estar mais próxima do centroide de outro cluster; deste modo, os centroides não se alteram mais
 - A solução final indica que a soma dos quadrados de cada observação até o centro do cluster alocada (WCSS) foi minimizada


$$\text{WCSS} = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

Ilustração do K-means



- Ao recalcular o valor do centroide para o ponto médio do cluster, as observações mudam de cluster, pois passam a estar mais próximas do centroide recalculado

Ilustração do K-means



- A convergência ocorre quando todas as observações já estão mais próximas do seu próprio centroide do que de outros, de modo que não há realocações

Identificação da quantidade de clusters

- Técnicas para a identificação da quantidade de clusters no K-means
 - **Método de Elbow:** calcula-se a soma total dos quadrados dentro dos clusters (WCSS) para várias opções de K (quantidade de clusters). Em seu gráfico, busca-se uma dobra (“cotovelo”), ou seja, o ponto a partir do qual a diminuição na WCSS não é mais tão expressiva, mesmo aumentando a quantidade de clusters
 - **Método da Silhueta:** para cada observação, calcula-se: (b) sua distância média para o cluster mais próximo onde não esteja alocada; (a) sua distância média dentro do cluster onde está alocada

$$\text{silhueta} = \frac{(b-a)}{\max(a,b)}$$

Quanto mais próximo de 1, melhor a clusterização. Quanto mais próximo de -1, pior!

- Em seguida, calcula-se o coeficiente de silhueta médio para todas as observações. O procedimento é realizado para várias opções de K

Considerações

- Alguns aspectos relevantes
 - A análise de cluster é bastante sensível à presença de outliers
 - Quando há variáveis categóricas, aplica-se a Análise de Correspondência
 - O output do método hierárquico pode ser utilizado como input para o método não hierárquico para a identificação inicial da quantidade de clusters
 - O método não hierárquico k-means pode ser aplicado em amostras maiores, pois o dendrograma pode tornar-se difícil de analisar quando há muitas observações

Referência / Sugestão de Leitura

- Fávero, Luiz Paulo; Belfiore, Patrícia. (2024). Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. Rio de Janeiro: LTC.

Larissa Dos Santos Magistrali 867.843.400-78

Obrigado!

Wilson Tarantin Junior | [linkedin.com/in/wilson-tarantin-junior-359476190](https://www.linkedin.com/in/wilson-tarantin-junior-359476190)

MBAUSP
ESALQ