

MBA EM **DATA SCIENCE
E ANALYTICS**

**UNSUPERVISED
MACHINE LEARNING:
Análise Fatorial e PCA**

Prof. Dr. Wilson Tarantin Junior

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98


Larissa Dos Santos Magistral: 867.843.400-78

MBAUSP
ESALQ

Contextualização

- Quando aplicar a análise fatorial?
 - Quando as **variáveis forem métricas**: depende das correlações de Pearson
 - Trata-se do **agrupamento das variáveis** originais em fatores, então busca-se analisar o comportamento conjunto dessas variáveis. Os objetivos podem ser:
 - Redução estrutural, ou seja, diminuição da dimensão do banco de dados
 - Análise de construtos pela identificação das variáveis alocadas aos fatores
 - Elaboração de rankings para classificação com base nos fatores extraídos
 - Criação de fatores ortogonais para posterior uso em modelos supervisionados

Contextualização



- A figura ilustra uma aplicação onde foram selecionados apenas os 2 primeiros fatores extraídos da análise fatorial PCA, visando uma redução de dimensionalidade do banco de dados

Contextualização

- Exemplos de aplicação
 - Geração de indicadores socioeconômicos
 - Avaliação de desempenho acadêmico
 - Gestão de marcas (pesquisa de opinião e percepção)
 - Testes psicológicos (traços psicológicos ou construtos não observáveis)
 - ...

Contextualização

- Análise fatorial por componentes principais
 - Componentes principais: método de determinação dos fatores que se baseia na criação de fatores não correlacionados a partir da combinação linear das variáveis originais
- Análise fatorial PCA: modelo não supervisionado de machine learning
 - O intuito é encontrar um padrão latente no que se refere às relações entre as variáveis
 - A técnica não tem caráter preditivo para observações que não estejam presentes na amostra. Se mudarem as observações (e/ou as variáveis), novos fatores atualizados devem ser gerados

Implementação da Técnica

Larissa Dos Santos Magistrali 867.843.400-78

Matriz de correlações de Pearson

- Procedimento inicial
 - A PCA fundamenta-se na **existência de correlações** entre variáveis originais para a criação dos fatores
 - Coeficiente de correlação de Pearson: relação linear entre duas variáveis métricas
 - Correlações mais próximos dos valores extremos (-1; +1) propiciam a extração de um único fator, pois indicam existência de relação entre as variáveis
 - Correlações mais próximos de zero propiciam a extração de diferentes fatores, pois indicam que a relação entre as variáveis é (praticamente) inexistente

Matriz de correlações de Pearson

- Criação da matriz
- Representação da matriz de correlações (ρ) para K variáveis métricas e a expressão de cálculo do coeficiente de correlação de Pearson para pares de variáveis

$$\rho = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1k} \\ \rho_{21} & 1 & \dots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \dots & 1 \end{bmatrix}$$

$$\rho_{12} = \frac{\sum_{i=1}^n (X_{1i} - \bar{X}_1) \cdot (X_{2i} - \bar{X}_2)}{\sqrt{\sum_{i=1}^n (X_{1i} - \bar{X}_1)^2} \cdot \sqrt{\sum_{i=1}^n (X_{2i} - \bar{X}_2)^2}}$$

Adequação global da análise

- A extração de fatores é adequada?
 - Para que a análise fatorial seja viável, devem existir valores mais elevados (em direção a -1 e +1) e estatisticamente significantes na matriz de correlações
 - Para avaliar a adequação global da análise fatorial nos dados, utiliza-se o teste de esfericidade de Bartlett
 - Os coeficientes de correlação de Pearson são estatisticamente diferentes de zero?
 - Compara-se a matriz de correlações com a matriz identidade de mesma dimensão; espera-se que tais matrizes sejam estatisticamente diferentes para que a análise fatorial seja aplicável

Adequação global da análise

- Teste de esfericidade de Bartlett

$$H_0: \rho = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1k} \\ \rho_{21} & 1 & \dots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \dots & 1 \end{bmatrix} = I = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

$$H_1: \rho = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1k} \\ \rho_{21} & 1 & \dots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \dots & 1 \end{bmatrix} \neq I = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

$$\chi^2_{Bartlett} = - \left[(n - 1) - \left(\frac{2 \cdot k + 5}{6} \right) \right] \cdot \ln |D| \quad \text{com} \quad \frac{k \cdot (k-1)}{2} \quad \text{graus de liberdade}$$

Autovalores

- A matriz de correlações (ρ) de dimensão $K \times K$ apresenta K autovalores (λ) obtidos como:

- Solução do $\det(\rho - \lambda \cdot I) = 0$, que é equivalente a
$$\begin{bmatrix} 1 - \lambda & \rho_{12} & \dots & \rho_{1k} \\ \rho_{21} & 1 - \lambda & \dots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \dots & 1 - \lambda \end{bmatrix} = 0$$

- De onde obtém-se a equação característica da matriz; suas raízes são os autovalores
- Os autovalores mostram o percentual da variância compartilhada pelas variáveis originais para a formação de cada fator extraído, ou seja, mostram a quantidade de informação contida em cada fator → quantidade de variância que é explicada por cada fator**

Autovetores

- Os autovetores da matriz de correlações (ρ) são obtidos para cada um dos autovalores
- v_{1k}, v_{2k}, v_{kk} são os autovetores para o K-ésimo autovalor (λ) e são obtidos como:

$$\begin{bmatrix} 1 - \lambda & \rho_{12} & \dots & \rho_{1k} \\ \rho_{21} & 1 - \lambda & \dots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \dots & 1 - \lambda \end{bmatrix} \cdot \begin{bmatrix} v_{1k} \\ v_{2k} \\ \vdots \\ v_{kk} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \rightarrow \begin{cases} (1 - \lambda) \cdot v_{1k} + \rho_{12} \cdot v_{2k} + \dots + \rho_{1k} \cdot v_{kk} = 0 \\ \rho_{21} \cdot v_{1k} + (1 - \lambda) \cdot v_{2k} + \dots + \rho_{2k} \cdot v_{kk} = 0 \\ \vdots \\ \rho_{k1} \cdot v_{1k} + \rho_{k2} \cdot v_{2k} + \dots + (1 - \lambda) \cdot v_{kk} = 0 \end{cases}$$

- Os autovetores contêm as combinações das variáveis originais que expressam os principais padrões das correlação nos dados, ou seja, como as variáveis se comportam juntas e os contrastes entre elas. Assim, apresentam as dimensões latentes do relacionamento entre as variáveis originais**

Obtenção dos fatores

- Para extrair os fatores são necessários os scores fatoriais
- **Scores fatoriais:** são os parâmetros que relacionam o fator com as variáveis originais, representados em um modelo linear
- Para K variáveis originais, existem, no máximo, K fatores ($F_1, F_2, \dots, F_K$)
- Os scores fatoriais são obtidos a partir dos autovalores e autovetores provenientes da matriz de correlações

Scores fatoriais

- Definindo os scores
- A partir dos autovalores e autovetores, obtém-se os scores fatoriais $s_{1k}, s_{2k}, \dots, s_{kk}$
- São gerados K grupos de scores (é o limite máximo dos K fatores possíveis)

$$s_1 = \begin{pmatrix} s_{11} \\ s_{21} \\ \vdots \\ s_{k1} \end{pmatrix} = \begin{pmatrix} \frac{v_{11}}{\sqrt{\lambda_1}} \\ \frac{v_{21}}{\sqrt{\lambda_1}} \\ \vdots \\ \frac{v_{k1}}{\sqrt{\lambda_1}} \end{pmatrix} \quad s_2 = \begin{pmatrix} s_{12} \\ s_{22} \\ \vdots \\ s_{k2} \end{pmatrix} = \begin{pmatrix} \frac{v_{12}}{\sqrt{\lambda_2}} \\ \frac{v_{22}}{\sqrt{\lambda_2}} \\ \vdots \\ \frac{v_{k2}}{\sqrt{\lambda_2}} \end{pmatrix} \quad s_k = \begin{pmatrix} s_{1k} \\ s_{2k} \\ \vdots \\ s_{kk} \end{pmatrix} = \begin{pmatrix} \frac{v_{1k}}{\sqrt{\lambda_k}} \\ \frac{v_{2k}}{\sqrt{\lambda_k}} \\ \vdots \\ \frac{v_{kk}}{\sqrt{\lambda_k}} \end{pmatrix}$$

Obtenção dos fatores

- Relações lineares para os K fatores
- O valor do fator F é obtido com as variáveis X transformadas pelo Z-Score (ZX)
- Tais fatores são ortogonais entre si, ou seja, não são correlacionados

$$F_{1i} = \frac{v_{11}}{\sqrt{\lambda_1}} \cdot ZX_{1i} + \frac{v_{21}}{\sqrt{\lambda_1}} \cdot ZX_{2i} + \dots + \frac{v_{k1}}{\sqrt{\lambda_1}} \cdot ZX_{ki}$$

$$F_{2i} = \frac{v_{12}}{\sqrt{\lambda_2}} \cdot ZX_{1i} + \frac{v_{22}}{\sqrt{\lambda_2}} \cdot ZX_{2i} + \dots + \frac{v_{k2}}{\sqrt{\lambda_2}} \cdot ZX_{ki}$$

$$F_{ki} = \frac{v_{1k}}{\sqrt{\lambda_k}} \cdot ZX_{1i} + \frac{v_{2k}}{\sqrt{\lambda_k}} \cdot ZX_{2i} + \dots + \frac{v_{kk}}{\sqrt{\lambda_k}} \cdot ZX_{ki}$$

Seleção de fatores

- Todos os K fatores serão utilizados?
- Embora seja possível estabelecer a priori quantos fatores são desejados, é fundamental realizar uma análise por meio da magnitude dos autovalores
- **Lembrando:** os autovalores indicam o percentual da variância compartilhada pelas variáveis originais para a formação de cada fator
- Neste sentido, fatores formados a partir de autovalores menores do que 1 podem não ter representatividade. O critério de Kaiser (ou critério da raiz latente) indica que sejam considerados apenas fatores correspondentes a autovalores > 1
- Autovalor > 1 : fator explica mais variância do que uma variável original isoladamente

Cargas fatoriais

- Análise da composição dos fatores
 - As cargas fatoriais mostram as correlações de Pearson entre os fatores e as variáveis originais
 - Pode ser interpretada como a importância de cada variável original para a constituição daquele fator em particular
 - Quanto maior a carga fatorial, mais aquele fator é influenciado pela variável original

Comunalidades

- Composição dos fatores selecionados
 - Ao utilizar o critério da raiz latente, apenas os fatores que são derivados de autovalores maiores que 1 serão considerados
 - As comunalidades mostram a variância total compartilhada, para cada variável, em todos os fatores extraídos e selecionados com base no critério da raiz latente
 - É possível analisar se houve perda de variância, por variável, após a exclusão dos fatores por meio do critério da raiz latente
 - Quanta informação das variáveis originais são retidas nos fatores selecionados?

Criação de rankings

- Soma ponderada e ordenamento
 - Para criar rankings a partir dos fatores obtidos utilizando o critério da soma ponderada e ordenamento, para cada observação da amostra, calcula-se:
 - $R_i = (F_{1i} \times \% \text{ var. comp. } F_1) + (F_{2i} \times \% \text{ var. comp. } F_2) + \dots + (F_{ki} \times \% \text{ var. comp. } F_k)$
 - Em resumo, multiplica-se o resultado obtido para cada fator pelo respectivo percentual de variância compartilhada e depois é realizado o ordenamento do resultado da variável

Referência / Sugestão de Leitura

- Fávero, Luiz Paulo; Belfiore, Patrícia. (2024). Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. Rio de Janeiro: LTC.
- **Para revisar os conceitos de álgebra linear:**
 - Anton, Howard; Rorres, Chris (2012). Álgebra Linear com Aplicações. 10 ed. Bookman.
 - Steinbruch, Alfredo; Winterle, Paulo (1995). Álgebra Linear. 1 ed. Pearson Universidades.

Obrigado!

Wilson Tarantin Junior | [linkedin.com/in/wilson-tarantin-junior-359476190](https://www.linkedin.com/in/wilson-tarantin-junior-359476190)

MBAUSP
ESALQ