

MBA EM **DATA SCIENCE
E ANALYTICS**

**UNSUPERVISED MACHINE
LEARNING: Análise de
Correspondência Simples
e Múltipla**

Prof. Dr. Wilson Tarantin Junior

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98


Larissa Dos Santos Magistral: 867.843.400-78

MBAUSP
ESALQ

Contextualização

- Quando aplicar a análise de correspondência?
 - Quando o objetivo for analisar variáveis categóricas (qualitativas)
 - O intuito é verificar se há associação estatisticamente significativa entre as variáveis e suas categorias, criando um **mapa perceptual** para visualizar tais associações
 - Caso exista uma variável quantitativa que deva participar da análise, é necessário que ela passe, previamente, por um procedimento de categorização
 - Exemplo: a idade é uma variável quantitativa (25, 42, 50, 73, 81 anos); poderia ser categorizada como faixas de idade: 0-30 anos, 31-60 anos, 61-90 anos...

Contextualização



- A figura ilustra um mapa perceptual formado por duas variáveis categóricas; a proximidade entre as categorias das variáveis indica o motivo da associação

Contextualização

- A análise de correspondência é uma técnica não supervisionada (exploratória)
 - Avalia a relação conjunta entre as variáveis (interdependência)
 - Não há a especificação de modelos do tipo $Y = f(X)$
 - Não é adequada para fins de inferência
 - Se novas observações forem adicionadas aos dados, é adequado refazer a análise

Contextualização

- Exemplos de aplicação
 - Faixa de renda e acesso ao crédito
 - Tipo de escola frequentada e aprovação no vestibular
 - Severidade dos sintomas da doença e comorbidades
 - Qualidade do produto, nível de satisfação do cliente e recomendação de compra
 - Outros...

Contextualização

- Evita o problema de ponderação arbitrária na análise de variáveis qualitativas
 - Por exemplo: variáveis geradas em escala likert
 - Concordo plenamente; concordo parcialmente; não concordo, nem discordo; discordo parcialmente; discordo plenamente
 - Cada ponto da escala é uma categoria da variável na análise de correspondência
 - A mesma lógica aplica-se a qualquer variável qualitativa

Análise de Correspondência Simples

Larissa Dos Santos Magistrali 867.843.400-78

Contextualização

- Também conhecida como ANACOR
 - Quando o objetivo for estudar a associação entre duas variáveis e suas categorias
 - É possível separar a ANACOR em duas etapas:
 1. Análise da significância estatística da associação entre as variáveis e suas categorias a partir do teste qui-quadrado (χ^2)
 2. Elaboração e interpretação do mapa perceptual

Teste qui-quadrado para associação

Larissa Dos Santos Magistrali 867.843.400-78

Análise da associação

- Tabela de contingência
- Inicia-se com as frequências absolutas observadas para cada par de categorias das variáveis: trata-se de uma tabela de classificação cruzada (*cross-tabulation*)

		Variável B					
		Categoria 1	Categoria 2	Categoria 3	...	Categoria J	Total
Variável A	Categoria 1	n_{11}	n_{12}	n_{13}	...	n_{1J}	Σ_{L1}
	Categoria 2	n_{21}	n_{22}	n_{23}	...	n_{2J}	Σ_{L2}
	Categoria 3	n_{31}	n_{32}	n_{33}	...	n_{3J}	Σ_{L3}
	...	...	...	...	...	...	...
	Categoria I	n_{I1}	n_{I2}	n_{I3}	...	n_{IJ}	Σ_{LI}
	Total	Σ_{C1}	Σ_{C2}	Σ_{C3}	...	Σ_{CJ}	N

Análise da associação

- Tabela de frequências absolutas esperadas
- Para a célula referente às categorias 1 das duas variáveis, a frequência absoluta esperada é:

$$freq. absoluta esperada_{11} = \frac{(\sum L1 \cdot \sum C1)}{N}$$

- O mesmo cálculo é realizado para cada par de categorias da tabela de contingência, mantendo-se as respectivas correspondências de linha e coluna no numerador

Análise da associação

- Tabela de resíduos
- Para a célula referente às categorias 1 das duas variáveis, o valor do resíduo é:

$$\text{resíduo}_{11} = \text{freq. absoluta observada}_{11} - \text{freq. absoluta esperada}_{11}$$

- O mesmo cálculo é realizado para cada par de categorias da tabela de contingência

Análise da associação

- Tabela com os valores χ^2
- Para a célula referente às categorias 1 das duas variáveis, o valor da estatística χ^2 é:

$$\chi_{11}^2 = \frac{(\text{resíduo}_{11})^2}{\text{freq. absoluta esperada}_{11}}$$

- O mesmo cálculo é realizado para cada par de categorias da tabela de contingência
- Em seguida, os valores de todas as células são somados para obter o valor χ^2 total
- **O χ^2 total é a estatística de teste usada para avaliar a significância da associação entre as variáveis qualitativas**

Análise da associação

- Teste de hipótese
 - Com base no valor χ^2 total, realiza-se o seguinte teste:
 - H_0 : as variáveis se associam de forma aleatória (são independentes)
 - H_1 : a associação entre as variáveis não se dá de forma aleatória (há dependência)
 - Dados o nível de significância e os graus de liberdade, se o valor da estatística χ^2 for maior do que o valor crítico, há associação significativa entre as duas variáveis (H_1)
 - Valor crítico da distribuição χ^2 com $(I - 1) \cdot (J - 1)$ graus de liberdade

Aprofundando a análise de associação

- Resíduos padronizados e resíduos padronizados ajustados
- Enquanto a análise do χ^2 permite verificar se há ou não a dependência entre as duas variáveis, a análise de resíduos padronizados ajustados permite aprofundar a análise com **foco nas categorias das variáveis**
 - Como as categorias de uma variável se relacionam com as categorias da outra variável?
- Observa-se o excesso de ocorrências de casos nos cruzamentos entre as categorias das variáveis para identificar a associação entre categorias

Aprofundando a análise de associação

- Tabela de resíduos padronizados
- Para a célula referente às categorias 1 das duas variáveis, o resíduo padronizado é:

$$\text{resíduo padronizado}_{11} = \frac{\text{resíduo}_{11}}{\sqrt{\text{freq. absoluta esperada}_{11}}}$$

- O mesmo cálculo é realizado para cada par de categorias da tabela de contingência

Aprofundando a análise de associação

- Tabela de resíduos padronizados ajustados
- Para a célula referente às categorias 1 das duas variáveis, o resíduo padronizado ajustado é:

$$\text{resíduo padronizado ajustado}_{11} = \frac{\text{resíduo padronizado}_{11}}{\sqrt{\left[\left(1 - \frac{\Sigma_{C1}}{N}\right) \cdot \left(1 - \frac{\Sigma_{L1}}{N}\right)\right]}}$$

- O mesmo cálculo é realizado para cada par de categorias da tabela de contingência

Aprofundando a análise de associação

- Tabela de resíduos padronizados ajustados
- **Análise:** se o valor do resíduo padronizado ajustado em certa célula for maior do que 1,96, interpreta-se que existe associação significativa, ao nível de significância de 5%, entre as duas categorias que interagem na célula; se for menor do que 1,96 não há associação estatisticamente significativa entre elas
- 1,96 é o valor crítico da normal padrão para o nível de significância de 5%

Elaboração do mapa perceptual

Autovalores

- Determinar os autovalores (λ)
- A quantidade (m) de autovalores depende da quantidade de categorias nas variáveis
 - $m = \min(I - 1, J - 1)$
- Os autovalores referem-se às inércias (variâncias) principais parciais e são base para determinar a inércia principal total e o percentual da inércia principal total em cada dimensão do mapa perceptual
- Portanto, interpreta-se quanta informação está representada em cada eixo do mapa perceptual e o quanto as primeiras dimensões explicam a associação entre variáveis

Autovalores

- Determinar os autovalores (λ)
- Como base para o cálculo dos autovalores, inicialmente, define-se a matriz A
- Um modo de obter a matriz A, baseando-se nas etapas anteriores, é fazer para cada célula da matriz de resíduos padronizados o seguinte cálculo:

$$\text{matriz } A_{11} = \frac{\text{resíduo padronizado}_{11}}{\sqrt{N}}$$

- A partir da matriz A, obtém-se a matriz W: $\mathbf{W} = \mathbf{A}' \cdot \mathbf{A}$

Autovalores

- Determinar os autovalores (λ)
 - Com base na matriz W , os autovalores são obtidos pela solução: **$\det(W - \lambda \cdot I) = 0$**
 - I é a matriz identidade
 - Exemplo para uma tabela de contingência 3x3:

$$\begin{bmatrix} w_{11} - \lambda & w_{12} & w_{13} \\ w_{21} & w_{22} - \lambda & w_{23} \\ w_{31} & w_{32} & w_{33} - \lambda \end{bmatrix} = 0$$

Autovalores

- Determinar os autovalores (λ)
- Pelos autovalores encontra-se o percentual da inércia principal total de cada dimensão

$$\% \text{ da inércia por dimensão} = \frac{\lambda_{\text{dimensão}}}{\lambda_{\text{total}}}$$

- Quanto maior a inércia principal total e o χ^2 , mais forte é a associação entre as variáveis

$$\text{inércia principal total} = \frac{\chi^2}{N}$$

$$\text{inércia principal total} = \lambda_1 + \lambda_2 + \cdots + \lambda_m$$

Massas

- Determinar as massas das variáveis em linha e em coluna
- As massas representam a influência que cada categoria exerce sobre as demais categorias de sua variável
- Com base nos “totais” da tabela de contingência, para a categoria 1 das variáveis, obtém-se as massas:

$$\text{Massa Linha}_1 = \frac{\Sigma_{L1}}{N}$$

$$\text{Massa Coluna}_1 = \frac{\Sigma_{C1}}{N}$$

- O mesmo cálculo é realizado para as demais categorias das variáveis para que se obtenha as matrizes de massas das linhas ($\mathbf{D}_l$) e massas das colunas ($\mathbf{D}_c$)

Autovetores

- Determinar os autovetores
- É possível encontrar os autovetores a partir dos autovalores (λ) calculados, de modo que cada autovalor gera seus autovetores
- Para o autovalor k define-se seu respectivo valor singular $\sigma_k = \sqrt{\lambda_k}$ e é feito o seguinte:
- Substitui o autovalor na matriz $(\mathbf{W} - \lambda \cdot \mathbf{I})$, multiplica por um vetor coluna e iguala a zero. Resolvendo o sistema de equações, é possível encontrar o autovetor da variável coluna ($\mathbf{v}$). Com base nele, encontra-se o autovetor da variável linha ($\mathbf{u}$):

$$\mathbf{u}_k = \text{Matriz } A \cdot \begin{pmatrix} v_k \\ \sigma_k \end{pmatrix}$$

Coordenadas

- Obter as coordenadas das categorias: **variável em linha na tabela**

- Coordenadas das abscissas (X)

$$X_l = \left(\sigma_1 \cdot \frac{1}{\sqrt{D_l}} \right) \cdot u_1$$

- Coordenadas das ordenadas (Y)

$$Y_l = \left(\sigma_2 \cdot \frac{1}{\sqrt{D_l}} \right) \cdot u_2$$

- E assim sucessivamente para as m dimensões (m = quantidade de autovalores)

Coordenadas

- Obter as coordenadas das categorias: **variável em coluna na tabela**

- Coordenadas das abscissas (X)

$$X_c = \left(\sigma_1 \cdot \frac{1}{\sqrt{D_c}} \right) \cdot v_1$$

- Coordenadas das ordenadas (Y)

$$Y_c = \left(\sigma_2 \cdot \frac{1}{\sqrt{D_c}} \right) \cdot v_2$$

- E assim sucessivamente para as m dimensões (m = quantidade de autovalores)

Análise de Correspondência Múltipla

Larissa Dos Santos Magistrali 867.843.400-78

Contextualização

- Na Análise de Correspondência Múltipla (ACM) o objetivo é analisar a associação entre mais de duas variáveis categóricas
- Só participam da ACM as variáveis que apresentarem associação estatisticamente significativa com pelo menos uma outra variável contida na análise
- Antes de elaborar a ACM é importante realizar o teste χ^2 para cada par de variáveis. Se alguma delas não apresentar associação estatisticamente significativa com pelo menos uma outra, então não é incluída na ACM (retira da análise)
- A ACM apresenta a mesma lógica de análise definida na ANACOR

Análise de Correspondência Múltipla

- 1º método: matriz binária $Z \rightarrow$ coordenadas-padrão
- A matriz binária é obtida pela transformação das variáveis qualitativas em variáveis binárias, ou seja, valores 0 ou 1 (ausência ou presença do atributo, respectivamente)
- Supondo que a matriz binária Z seja a tabela de contingência da ANACOR, é possível obter a inércia principal parcial das dimensões, autovalores, autovetores e, portanto, as coordenadas no mapa perceptual dessa matriz
- Quantidade de dimensões (λ) = $J - Q$, em que “J” é a quantidade total de categorias em todas as variáveis e “Q” a quantidade de variáveis

$$\text{inércia principal total} = \frac{J - Q}{Q}$$

Análise de Correspondência Múltipla

- Matriz binária Z: exemplo com 7 observações na amostra

ID	Variável A		Variável B			Variável C			
	Categ. 1	Categ. 2	Categ. 1	Categ. 2	Categ. 3	Categ. 1	Categ. 2	Categ. 3	Categ. 4
1	1	0	0	1	0	1	0	0	0
2	0	1	0	0	1	0	1	0	0
3	0	1	1	0	0	0	0	1	0
4	1	0	0	0	1	0	0	0	1
5	0	1	0	1	0	0	1	0	0
6	1	0	0	1	0	0	0	1	0
7	1	0	1	0	0	1	0	0	0

Análise de Correspondência Múltipla

- 2º método: matriz de Burt → coordenadas principais
 - A matriz de Burt é definida como: $B = Z' \cdot Z$
 - É possível combinar em uma única matriz o cruzamento de todos os pares variáveis e suas categorias, obtendo uma matriz que contém as frequências absolutas observadas para todos os cruzamentos
 - Ao considerar a matriz de Burt como uma tabela de contingência, é possível realizar uma ANACOR e obter as coordenadas das categorias das variáveis

Análise de Correspondência Múltipla

- Matriz de Burt: obtida com base na matriz Z do exemplo anterior

		Variável A		Variável B			Variável C			
		Categ. A1	Categ. A2	Categ. B1	Categ. B2	Categ. B3	Categ. C1	Categ. C2	Categ. C3	Categ. C4
Variável A	Categ. A1	4	0	1	2	1	2	0	1	1
	Categ. A2	0	3	1	1	1	0	2	1	0
Variável B	Categ. B1	1	1	2	0	0	1	0	1	0
	Categ. B2	2	1	0	3	0	1	1	1	0
	Categ. B3	1	1	0	0	2	0	1	0	1
Variável C	Categ. C1	2	0	1	1	0	2	0	0	0
	Categ. C2	0	2	0	1	1	0	2	0	0
	Categ. C3	1	1	1	1	0	0	0	2	0
	Categ. C4	1	0	0	0	1	0	0	0	1



Sugestões de Leituras/Referências

Referência:

- Fávero, Luiz Paulo; Belfiore, Patrícia. (2024). Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. Rio de Janeiro: LTC.

Sugestões de Leitura:

- Anton, H.; Rorres, C. (2012). Álgebra Linear com Aplicações. 10 ed. Bookman.
- Benzécri, J. P. (1992) Correspondence analysis handbook. 2 ed. Marcel Dekker.
- Greenacre, M. J. (1984) Theory and applications of correspondence analysis. Academic Press.
- Steinbruch, A.; Winterle, P. (1995). Álgebra Linear. 1 ed. Pearson Universidades.

Obrigado!

Wilson Tarantin Junior | [linkedin.com/in/wilson-tarantin-junior-359476190](https://www.linkedin.com/in/wilson-tarantin-junior-359476190)

MBAUSP
ESALQ