

MBA EM **DATA SCIENCE
E ANALYTICS**

Supervised Machine Learning: Análise de Regressão Simples e Múltipla

Prof. Dr. Luiz Paulo Fávero


MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Larissa Dos Santos Magistral 867.843.400-78




Reflexão

Modelos Supervisionados



“Diferentes pesquisadores, a partir de uma mesma base de dados, podem estimar diferentes modelos e, consequentemente, obter diferentes valores previstos do fenômeno em estudo. O objetivo é estimar modelos que, embora simplificações da realidade, apresentem a melhor aderência possível entre os valores reais e os valores previstos”.

Silberzahn, R.; Uhlmann, E. L. Many hands make tight work. **Nature**, v. 526, p. 189-191, Out 2015.




**“Todos os modelos são simplificações.
Em essência, todos os modelos estão
errados, mas alguns são úteis.”**

George E. P. Box

[18/10/1919 – 28/03/2013]


Reflexão

Modelos Supervisionados




Reflexão

Modelos Supervisionados




Reflexão

Modelos Supervisionados



Reflexão

Modelos Supervisionados





Agenda:

- 1 – Fundamentação teórica e conceitos em modelos de regressão;
- 2 – Especificação dos modelos GLM;
- 3 – Estimação dos parâmetros;
- 4 – Variáveis preditoras qualitativas: variáveis *dummy*;
- 5 – Procedimento Stepwise;
- 6 – Teste de normalidade dos resíduos;
- 7 – Modelos não lineares e transformação de Box-Cox;
- 8 – Diagnósticos de multicolinearidade e heterocedasticidade;
- 9 – Estimações em




SPYDER

The Scientific Python Development Environment

Modelos Supervisionados de Machine Learning

Modelos Lineares Generalizados (GLM)



Modelos Lineares Generalizados (GLM)


$$Y = f(X_1, X_2, X_3, \dots, X_k)$$

Modelo de Regressão	Característica da Variável Dependente
Linear	Quantitativa Normal
Com Transformação de Box-Cox	Quantitativa Normal Após a Transformação
Logística Binária	Qualitativa com 2 Categorias (<i>Dummy</i>)
Logística Multinomial	Qualitativa M ($M > 2$) Categorias
Poisson	Quantitativa com Valores Inteiros e Não Negativos (Dados de Contagem)
Binomial Negativo Poisson-Gama	Quantitativa com Valores Inteiros e Não Negativos (Dados de Contagem)

A close-up photograph of a hand in an orange sleeve reaching towards a row of colorful wooden blocks (yellow, blue, red, white, blue, white, orange, orange, orange, green) on a light blue surface. The hand is positioned as if about to knock over the blocks, which are arranged in a slightly curved line. The background is blurred, showing more of the hand and sleeve.

RELAÇÃO DE CAUSA E EFEITO?

Correlação não Implica Causalidade



Messerli, F. (2012).⁸ Chocolate Consumption, Cognitive Function, and Nobel Laureates. *The New England Journal of Medicine*, v. 367, p.1562-1564.



The NEW ENGLAND
JOURNAL of MEDICINE

x =nicolas cage films

y =swimming pool drownings

x =Divorces in Maine

y =Margarine consumption

Spurious correlations

CORRELATION DOES NOT EQUAL CAUSATION

x =cheese eating

y =Fatal Liner Tangles




x =shark attacks

y =tomatoes


TYLER VIGEN

Modelos Supervisionados de Machine Learning

Modelos Lineares Generalizados (GLM)



Manual de Análise de Dados



<https://www.grupogen.com.br/manual-de-analise-de-dados-favero-e-belfiore>

Cupom de desconto para os alunos dos MBAs USP/Esalq

Cupom FAVERO30 - 30% de desconto

Validade: 30/04/2026

Regressão Linear Simples

Objetivo:

Desenvolver uma equação linear que apresente a relação entre uma variável dependente e uma variável explicativa.

Equação linear de uma reta num plano cartesiano:






$$Y_i = \alpha + \beta \cdot X_i + u_i$$



em que temos um intercepto (α), um coeficiente de inclinação da reta (β), uma variável explicativa X e um termo de erro u .



ARQUIVO
“tempodist.xls”







Análise de Regressão: Coeficiente de Ajuste do Modelo (R^2)

Indica o percentual de variância da variável Y que é devido ao comportamento de variação conjunta da(s) variável(is) explicativa(s) X . Varia de 0 a 1 e, quanto maior o coeficiente, maior o poder preditivo do modelo de regressão, ou seja, maior o poder de explicação do comportamento da variável dependente frente ao comportamento da(s) variável(is) explicativa(s).



Análise de Regressão: Coeficiente de Ajuste do Modelo (R^2)



Comportamento do R^2 para diferentes regressões lineares simples.

Análise de Regressão: Estimação dos Parâmetros

Critérios:




1 – Soma dos erros igual a zero:

$$\sum_{i=1}^n u_i = 0$$

2 – Soma dos erros ao quadrado sendo a mínima possível:


$$\sum_{i=1}^n u_i^2 = \text{mín}$$

Parâmetros α e β podem ser estimados por meio do método dos mínimos quadrados ordinários (MQO), em que a somatória dos quadrados dos termos de erro é minimizada.




Análise de Regressão: Cálculo do R^2


$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (u_i)^2}$$



Apenas Parâmetros e R^2 ?



Apenas Parâmetros e R^2 ?



X Mean: 54.2659224
Y Mean: 47.8313999
X SD : 16.7649829
Y SD : 26.9342120
Corr. : -0.0642526



Modelos de Regressão

no  **SPYDER**
Scientific Python IDE

Significância Estatística do Modelo

- **Teste F :** Permite analisar se pelo menos um dos β 's é estatisticamente significativo para a explicação do comportamento de Y .

- **Hipóteses:**
 $H_0: \beta_1 = \beta_2 = \beta_3 = \dots = \beta_k = 0$
 $H_1: \text{pelo menos um } \beta \neq 0$



Na rejeição da hipótese nula, pelo menos um dos β 's será estatisticamente diferente de zero para explicar o comportamento de $Y \rightarrow$ p-valor abaixo do nível crítico (5% (0,05), usualmente).

Significância Estatística dos Parâmetros do Modelo

- **Teste t :** Permite analisar se cada um dos parâmetros, individualmente, é estatisticamente diferente de zero (no caso de regressão simples, apresenta a mesma significância da estatística F).

- **Hipóteses:**
 $H_0: \beta = 0$
 $H_1: \beta \neq 0$



Avalia-se a significância estatística de cada parâmetro do modelo, para determinado nível de significância → p-valor abaixo do nível crítico para cada parâmetro (5% (0,05), usualmente).

Regressão Múltipla

Qual a diferença entre um modelo de regressão simples para um modelo de regressão múltipla?

A inclusão de novas variáveis explicativas no modelo!

A forma funcional passa a ser a seguinte:

$$Y_i = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \beta_3 \cdot X_{3i} + \dots + \beta_k \cdot X_{ki} + u_i$$



Comparação entre Modelos

Quando houver o intuito de se compararem os resultados das estimações de dois modelos com quantidades distintas de parâmetros e/ou obtidos a partir de amostras com tamanhos diferentes, faz-se necessário o uso do R^2 ajustado.

$$R^2_{ajust.} = 1 - \frac{n-1}{n-1-k} \cdot (1 - R^2)$$

n : tamanho da amostra;

k : quantidade de variáveis X explicativas.





Variáveis Preditoras Qualitativas: Variáveis *Dummy* em Modelos de Regressão

Variáveis Explicativas (X) Qualitativas

- Modelagem com variáveis explicativas (X) qualitativas.
- É muito comum observar que diversas variáveis explicativas podem se apresentar de maneira qualitativa (exemplo: rating de crédito, setor de atuação, etc.).
- Dado que tais características não possuem média e nem variância, como incorporá-las ao modelo de regressão?

01001111 1111100 0111101 0111101 1101001 11001010 11101000 10011110 11101111 10100000 10010111 00100001 00010111 01000011 00011100
11100010 10011100 01100010 01011111 11010011 10001100 10001101 01110101 10010000 01010101 01110000 10111110 10110010 10101010 10011001
11001011 01001001 11100010 01011011 11000101 10001010 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011
00100011 00011111 00001000 01011011 01001111 10100101 00101010 00001010 00001010 00001010 00001010 00001010 00001010 00001010 00001010
10111001 01010010 01100011 00000100 00000101 10011010 00101010 10001010 10001010 10001010 10001010 10001010 10001010 10001010 10001010
00100011 11010010 10000111 00011000 10011101 01111011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
01000101 01010001 00100101 11110001 00110101 01111011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10001100 10001101 01110101 10010000 01010101 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011
10001011 01000011 01000111 00011110 11001011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10100101 01111001 00111001 11001011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10001011 01000011 01000111 00011110 11001011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10100101 01111001 00111001 11001011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10001100 00101000 00010110 00111010 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
01111011 01011010 10001100 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010
00100100 10101110 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010
01110000 10111110 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010 10101010
00000010 11100100 00011010 10010000 00000000 111010010 10000111 00011000 10011011 10011011 10011011 10011011 10011011 10011011 10011011
010001101101111 10010011 10000000 00010101 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10011001 11010100 10001101 01100111 10000000 00010101 01010001 00100101 11110001 00110011 10011011 10011011 10011011 10011011 10011011
11100001 10100100 01001000 00101011 10000000 00010101 10000000 00010101 10011011 10011011 10011011 10011011 10011011 10011011 10011011
01100011 11111010 01111011 01111011 10001010 11101000 10011110 11101111 10100000 00010101 00000001 00010101 00000001 00010101 00011000
11100010 10011100 01100010 01010101 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
11001011 01001001 11100010 01010101 10001000 10001101 01111011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
00100011 00011111 00001000 01010101 10000000 00010101 010001101 01110101 10010000 01010101 101111 10010011 10000000 01100110
10111001 01010010 01100011 00000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011
00100011 11010010 10000111 00011000 00000001 01000011 01000011 00011110 01000011 01000011 01000011 01000011 01000011 01000011 01000011
01000101 01010001 00100101 11110001 00000001 01111001 00111001 11001011 10000000 00010101 01000011 01000011 01000011 01000011 01000011
11001010 11010000 10011110 11101111 00000001 01111001 00111001 11001011 10000000 00010101 01000011 01000011 01000011 01000011 01000011
10001100 100001101 01101010 10010000 00000000 01111001 00111001 11001011 10000000 00010101 01000011 01000011 01000011 01000011 01000011
10001011 01000011 01000111 00011110 10010101 00010100 00010110 00110101 10000000 00010101 01000011 01000011 01000011 01000011 01000011
10100101 01111001 00111001 11001011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10011000 00101000 00010110 00111010 10000000 00010101 10000000 00010101 10011011 10011011 10011011 10011011 10011011 10011011 10011011
10111011 0101010 10001100 10101010 11101101 00000001 01111001 00111001 11001011 10000000 00010101 01000011 01000011 01000011 01000011
00100100 10101010 10101100 01011111 00111001 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011 01000011
10010111 00000001 00010111 01000011 00011100 11100011 10001100 10001101 01110101 10000000 01010101
10110000 10111110 1010010 10110101 10011001 11001011 10001011 01000011 01000011 01000011 00011110 00011010 10011011
00000010 11100100 0001010 10010010 10000010 00100011 00011111 1000010 01011011 01000111 10010101 01111001 00111001 11001011 01101010
010001101101111 10010011 10000000 01100110 10111001 01010010 01100011 1001100 00101000 0001010 00111010 10000010
10011001 11010100 10001101 01100111 00000101 00100011 11010010 10000111 00011000 10011011 01111011 0101010 10001100 10101010 11101100
11100001 10101000 01001000 00110111 00100001 01000101 01010001 00100101 11110001 00101111 00100100 1010110 10101100 00111011 00111001


Variáveis Explicativas (X) Qualitativas

Variáveis *dummy*

São variáveis categóricas que representam um atributo por meio de combinação binária (0 para a ausência ou 1 para presença).


E quando tivermos uma variável categórica com mais de uma categoria?

Neste caso, devemos incluir $n - 1$ *dummies*, em que n é a quantidade de categorias existentes na variável original.







Modelos Não Lineares e Transformações de Box-Cox

Modelos Não Lineares



Distribuição normal dos resíduos.



Resultados da aplicação de quatro diferentes formas funcionais em regressão.

Modelos Não Lineares e Transformações de Box-Cox

An Analysis of Transformations

G. E. P. Box and D. R. Cox

Journal of the Royal
Statistical Society.
Series B
(Methodological)
Vol. 26, No. 2 (1964),
pp. 211-252 (42 pages)
Published By: Wiley



<https://www.jstor.org/stable/2984418>

$$Y_{Box-Cox}^* = \frac{Y^\lambda - 1}{\lambda}$$


Qual o valor de λ (λ varia entre $-\infty$ e $+\infty$) que maximiza a aderência da distribuição da nova variável Y^* à normalidade?

Modelos Não Lineares e Transformações de Box-Cox

$Y_i = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Linear ($\lambda = 1$)
$Y_i^2 = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Quadrática ($\lambda = 2$)
$Y_i^3 = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Cúbica ($\lambda = 3$)
$\sqrt{Y_i} = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação de Raiz ($\lambda = 0,5$)
$\frac{1}{Y_i} = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Inversa ($\lambda = -1$)
$\ln(Y_i) = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Semilogarítmica ($\lambda = 0$) Expansão de Taylor

Modelos Não Lineares e Transformações de Box-Cox

$$\frac{Y_i^\lambda - 1}{\lambda} = \alpha + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \dots + \beta_k \cdot X_k + u_i$$



Diagnóstico de Multicolinearidade

- **Multicolinearidade:** consequência da existência de alta correlação entre duas ou mais variáveis explicativas (preditoras).
- Possibilidade de interpretações erradas pela eventual distorção dos sinais dos parâmetros.
- Erros nas previsões.
- **Como detectar a multicolinearidade?**
 - Sinais inesperados dos coeficientes.
 - Testes t não significantes e teste F significativo.




Diagnóstico de Multicolinearidade

$$Y_i = \alpha + \beta_1.X_{1i} + \beta_2.X_{2i} + \dots + \beta_k.X_{ki} + u_i$$

$$\mathbf{Y} = \mathbf{X}.\mathbf{b} + \mathbf{U}$$

$$\begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \dots \\ Y_n \end{bmatrix}_{n \times 1} = \begin{bmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ 1 & X_{31} & X_{32} & \dots & X_{3k} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & X_{n1} & X_{n2} & \dots & X_{nk} \end{bmatrix}_{n \times k+1} \cdot \begin{bmatrix} a \\ b_1 \\ b_2 \\ \dots \\ b_k \end{bmatrix}_{k+1 \times 1} + \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \dots \\ u_n \end{bmatrix}_{n \times 1}$$

$$\beta = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{Y})$$



Fontes Geradoras da Multicolinearidade

- 1 - Existência de variáveis que apresentam a mesma tendência durante alguns períodos, em decorrência da seleção de uma amostra que inclua apenas observações referentes a estes períodos.**
- 2 - Utilização de amostras com reduzido número de observações.**
- 3 - Utilização de valores defasados em algumas das variáveis explicativas como “novas” explicativas.**

Consequências da Multicolinearidade (Exemplo)

$$Y_i = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i}$$

(1) Correlação Baixa:

$$\mathbf{X} = \begin{bmatrix} 1 & 4 \\ 2 & 3 \end{bmatrix}$$

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 5 & 10 \\ 10 & 25 \end{bmatrix}$$

de onde vem que $\det(\mathbf{X}'\mathbf{X}) = 25$ e, portanto:

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{bmatrix} 1 & -0,4 \\ -0,4 & 0,2 \end{bmatrix}$$

Consequências da Multicolinearidade (Exemplo)

(2) Correlação Muito Alta:

$$\mathbf{X} = \begin{bmatrix} 1 & 4 \\ 2 & 7,9 \end{bmatrix}$$

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 5 & 19,8 \\ 19,8 & 78,41 \end{bmatrix}$$

de onde vem que $\det(\mathbf{X}'\mathbf{X}) = 0,01$ e, portanto:

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{bmatrix} 7.841 & -1.980 \\ -1.980 & 500 \end{bmatrix}$$

Consequências da Multicolinearidade

1 – As significâncias estatísticas dos parâmetros $\beta = (X'X)^{-1}X'Y$ são sensíveis às correlações entre as variáveis explicativas.

2 – Os elementos da diagonal principal da matriz $(X'X)^{-1}$ aparecem no denominador da estatística t . Como a presença da multicolinearidade gera valores muito altos na diagonal da referida matriz, como vimos, ocorre a redução no valor da estatística t , sem alteração no cálculo da estatística F .

Identificação da Multicolinearidade

Regressões auxiliares entre cada uma das explicativas e as demais explicativas:



$$\begin{aligned} X_2 &= \beta_1 + \beta_2 X_3 + \dots + \beta_{k-1} X_k \\ X_3 &= \beta_1 + \beta_2 X_2 + \dots + \beta_{k-1} X_k \\ &\vdots \\ X_k &= \beta_1 + \beta_2 X_2 + \dots + \beta_{k-1} X_{k-1} \end{aligned}$$

Estatísticas VIF (*Variance Inflation Factor*) e *Tolerance*:

$$\begin{aligned} \text{Tolerance} &= 1 - R_p^2 \\ \text{VIF} &= 1 / \text{Tolerance} \end{aligned}$$

em que o R_p^2 é o coeficiente de ajuste da regressão da variável explicativa X_p ($p = 2, 3, \dots, k$) com as demais variáveis explicativas.

Diagnóstico de Heterocedasticidade





Sugestões de Leituras/Referências

- FÁVERO, L. P.; BELFIORE, P. **Data science for business and decision making**. Cambridge: Academic Press, 2019.
- FÁVERO, L. P.; BELFIORE, P. **Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®**. Rio de Janeiro: GEN, 2024.
- GUJARATI, D. N. **Econometria básica**. 5. ed. Porto Alegre: Bookman, 2011.
- HEISS, F.; BRUNNER, D. **Using Python for introductory econometrics**. Independently Published, 2020.
- KUTNER, M. H.; NACHTSHEIN, C. J.; NETER, J. **Applied linear regression models**. 4. ed. Chicago: Irwin, 2004.
- McNULTY, K. **Handbook of regression modeling in people analytics: with examples in R and Python**. New York: CRC Press, 2022.
- OSWALD, F.; VIERS, V.; ROBIN, J.-M.; VILLEDIEU, P.; KENEDI, G. **Introduction to econometrics with R**. Syllabus, 2020. <https://scpoecon.github.io/ScPoEconometrics/>
- WOOLDRIDGE, J. M. **Introductory econometrics: a modern approach**. 5. ed. Mason: Cengage Learning, 2012.
- <https://itforum.com.br/coluna/machine-learning-e-modelos-supervisionados-o-uso-correto-do-glm-na-tomada-de-decisao/>

Obrigado!

Prof. Dr. Luiz Paulo Fávero |



MBAUSP
ESALQ