

MBA EM **DATA SCIENCE**
E ANALYTICS

Supervised Machine Learning: Modelagem Multinível

Prof. Dr. Luiz Paulo Fávero

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98




MODELAGEM MULTINÍVEL

Fundamentação teórica

Conceitos para a estimação de modelos multinível

Estimações em Python

Reflexão



Contexto


Machine Learning

Unsupervised

Análise de
Conglomerados

Componentes
Principais

Análise de
Correspondência



Supervised

Modelos Lineares
Generalizados (GLM)

Modelos Lineares
Generalizados
Multinível (GLMM)

O que são Modelos Multinível?

São modelos que reconhecem a existência de estrutura multinível ou hierárquica nos dados.



Stephen W. Raudenbush
University of Chicago

Hierarchical linear models: applications and data analysis methods. 2. ed. Thousand Oaks: Sage Publications, 2002.




Anthony S. Bryk
Stanford University


Estrutura Multinível




Estrutura Multinível




Estrutura Multinível




Estrutura Multinível




Estrutura Multinível



Estrutura Multinível



Estrutura Multinível



Estrutura Multinível

Escola 1:

$$Y_{i1} = \beta_{01} + \beta_{11} \cdot X_{i1} + \varepsilon_{i1}$$

Escola 2:

$$Y_{i2} = \beta_{02} + \beta_{12} \cdot X_{i2} + \varepsilon_{i2}$$

Escola 3:

$$Y_{i3} = \beta_{03} + \beta_{13} \cdot X_{i3} + \varepsilon_{i3}$$

Escola 4:

$$Y_{i4} = \beta_{04} + \beta_{14} \cdot X_{i4} + \varepsilon_{i4}$$

O Modelo Multinível

Nível 1

$$Y_{ij} = \beta_{0j} + \beta_{1j} \cdot X_{ij} + \varepsilon_{ij}$$

Nível 2

$$\beta_{0j} = \gamma_{00} + \gamma_{01} \cdot W_j + \nu_{0j}$$

$$\beta_{1j} = \gamma_{10} + \gamma_{11} \cdot W_j + \nu_{1j}$$

$$Y_{ij} = \underbrace{\left(\gamma_{00} + \gamma_{01} \cdot W_j + \nu_{0j} \right)}_{\text{intercepto com efeitos aleatórios}} +$$

**intercepto com
efeitos aleatórios**

$$+ \underbrace{\left(\gamma_{10} + \gamma_{11} \cdot W_j + \nu_{1j} \right) \cdot X_{ij}}_{\text{inclinação com efeitos aleatórios}} + \varepsilon_{ij}$$

**inclinação com
efeitos aleatórios**

O Modelo Multinível

$$Y_{ij} = \underbrace{\gamma_{00} + \gamma_{10} \cdot X_{ij} + \gamma_{01} \cdot W_j + \gamma_{11} \cdot W_j \cdot X_{ij}}_{\text{Efeitos Fixos}} + \underbrace{\nu_{0j} + \nu_{1j} \cdot X_{ij} + \varepsilon_{ij}}_{\text{Efeitos Aleatórios}}$$

- Os modelos tradicionais de regressão ignoram as interações entre variáveis no componente de efeitos fixos e as interações entre termos de erro e variáveis no componente de efeitos aleatórios.

Multilevel statistical models. 4. ed. Chichester: John Wiley & Sons, 2011.

Harvey Goldstein
Centre for Multilevel Modelling
University of Bristol



Variância dos Termos Aleatórios

Se as variâncias dos termos aleatórios ν_{0j} e ν_{1j} forem estatisticamente diferentes de zero, procedimentos tradicionais de estimação dos parâmetros do modelo, como mínimos quadrados ordinários, não serão adequados.



Barbara G. Tabachnick
California State University

Using multivariate statistics. 6. ed. Boston:
Pearson, 2013.



Linda S. Fidell
California State University

Dummies?

Apenas a inserção de **dummies de grupo** não capturaria os **efeitos contextuais**, visto que não permitiria que se separassem os efeitos observáveis dos não observáveis sobre a variável dependente.



Sophia Rabe-Hesketh
U. C. Berkeley

Multilevel and longitudinal modeling using Stata. 3. ed.
College Station: Stata Press, 2012.

Anders Skrondal
*Norwegian Institute of Public Health
University of Oslo
U. C. Berkeley*



Por que Utilizar?

Os modelos multinível permitem, portanto, o desenvolvimento de novos e mais bem elaborados constructos para predição e tomada de decisão.

“Dentro de uma estrutura de modelo com equação única, parece não haver uma conexão entre indivíduos e a sociedade em que vivem. Neste sentido, o uso de equações em níveis permite que o pesquisador ‘pule’ de uma ciência a outra: alunos e escolas, famílias e bairros, firmas e países. Ignorar esta relação significa elaborar análises incorretas sobre o comportamento dos indivíduos e, igualmente, sobre os comportamentos dos grupos. Somente o reconhecimento destas recíprocas influências permite a análise correta dos fenômenos.”

Methodology and epistemology of multilevel analysis.

London: Kluwer Academic Publishers, 2003.

Daniel Courgeau
*Institut National D'Études
Démographiques*





APLICAÇÕES DE MODELAGEM MULTINÍVEL

Aplicações

Business, Economics & Management

Periódico	Índice h5 (Google Scholar)	% / Modelos Supervisionados
Journal of Business Research	239	10,78%
Technological Forecasting and Social Change	209	12,71%
Journal of Retailing and Consumer Services	168	14,04%
Business Strategy and the Environment	159	12,15%
Energy Economics	159	11,83%
Finance Research Letters	152	3,75%
American Economic Review	146	6,88%
International Journal of Hospitality Management	138	4,59%
Management Science	138	8,15%
International Journal of Production Economics	137	8,57%
		9,26%

Aplicações

Engineering & Computer Science

Periódico	Índice h5 (Google Scholar)	% / Modelos Supervisionados
IEEE Conf. on Comp. Vision and Pattern Recog.	450	4,78%
Neural Information Processing Systems	371	3,56%
Int. Conf. on Learning Representations	362	6,22%
Advanced Materials	330	4,83%
Journal of Cleaner Production	298	3,42%
IEEE Access	288	2,53%
International Conference on Machine Learning	272	8,24%
Advanced Functional Materials	263	3,54%
European Conference on Computer Vision	262	2,89%
IEEE/CVF Int. Conf. on Computer Vision	256	3,38%
		4,28%

Aplicações

Health & Medical Sciences

Periódico	Índice h5 (Google Scholar)	% / Modelos Supervisionados
The New England Journal of Medicine	441	1,97%
The Lancet	375	2,34%
Cell	317	2,41%
JAMA	301	2,75%
Nature Medicine	279	0,98%
International Journal of Molecular Sciences	277	1,75%
Proceedings of the National Academy of Sciences	268	0,73%
Int. Journal of Env. Research and Public Health	258	0,45%
PLOS ONE	244	0,43%
BMJ	224	2,34%
		1,70%

Aplicações

Social Sciences

Periódico	Índice h5 (Google Scholar)	% / Modelos Supervisionados
Business Strategy and the Environment	159	0,97%
Computers & Education	152	0,34%
Education and Information Technologies	143	0,41%
Technology in Society	139	0,75%
Resources Policy	133	0,98%
Nature Human Behaviour	132	0,75%
Journal of Business Ethics	127	0,73%
Land Use Policy	120	0,45%
Energy Research & Social Science	117	0,43%
Education Sciences	116	0,97%
		0,64%

Pouca Utilização: Qual a Razão?

- Estrutura dos dados.
- Não consideração de natureza multinível nos dados.
- Capacidade computacional por vezes insuficiente, principalmente quando da existência de interações profundas.



Emmanuel Lazega
Institut d'Études Politiques de Paris

Multilevel network analysis for the social sciences: theory, methods and applications. New York: Springer, 2016.



Tom Snijders
University of Oxford

Aplicação

RAJAN, R.G.; ZINGALES, L.

What do we know about capital structure? Some evidence from international data.
Journal of Finance, v. 50-5, p. 1421-1460, 1995.

- Compustat Global e MSCI;

- 4.557 empresas;

- 7 países;

- período: 1987-1991.

Country	Local Market Index	Number of Firms
United States	S&P 500	2.583
Japan	Nikkei 500	514
Germany	FAZ Share Index	191
France	CAC General Index	225
Italy	MIB Current Index	118
United Kingdom	FT 500	608
Canada	TSE 300	318

$$\begin{aligned} \text{Leverage}_i = & \beta_0 + \beta_1 \cdot (\text{Tangible Assets})_i + \beta_2 \cdot (\text{Market to Book})_i \\ & + \beta_3 \cdot (\text{Log Sales})_i + \beta_4 \cdot (\text{ROA})_i + \varepsilon_i \end{aligned}$$

Aplicação

$$\begin{aligned} \text{Leverage}_i = & \beta_0 + \beta_1 \cdot (\text{Tangible Assets})_i + \beta_2 \cdot (\text{Market to Book})_i \\ & + \beta_3 \cdot (\text{Log Sales})_i + \beta_4 \cdot (\text{ROA})_i + \varepsilon_i \end{aligned}$$

Nível 1

$$\begin{aligned} \text{Leverage}_{ij} = & \beta_{0j} + \beta_{1j} \cdot (\text{Tangible Assets})_{ij} + \beta_{2j} \cdot (\text{Market to Book})_{ij} \\ & + \beta_{3j} \cdot (\text{Log Sales})_{ij} + \beta_{4j} \cdot (\text{ROA})_{ij} + \varepsilon_{ij} \end{aligned}$$

Nível 2

$$\beta_{0j} = \gamma_{00} + v_{0j}$$

$$\beta_{1j} = \gamma_{10} + v_{1j}$$

$$\beta_{2j} = \gamma_{20} + v_{2j}$$

$$\beta_{3j} = \gamma_{30} + v_{3j}$$


$$\beta_{4j} = \gamma_{40} + v_{4j}$$

Aplicação






RAJAN, R.G.; ZINGALES, L.

What do we know about capital structure? Some evidence from international data.

Journal of Finance, v. 50-5, p. 1421-1460, 1995.



Aplicação



Desafios em Modelagem Multinível

Interações Profundas e
Capacidade de Processamento

Métodos de Estimação dos
Parâmetros

Clusterização da Amostra

Estimação de
modelos com a
melhor aderência
possível entre os
valores reais e
previstos



Andrew Gelman

Multilevel Conference, 31 Out 2015, Columbia University, NYC.

MODELAGEM MULTINÍVEL

NO  SPYDER
Scientific Python IDE





Modelagem HLM2 com Dados Agrupados

Modelagem HLM2

Modelo Nulo

Nível 1

$$desempenho_{ij} = \beta_{0j} + \varepsilon_{ij}$$

Nível 2

$$\beta_{0j} = \gamma_{00} + v_{0j}$$

Substituindo...

$$desempenho_{ij} = \gamma_{00} + v_{0j} + \varepsilon_{ij}$$

LINHA
324 DO
SCRIPT

Modelagem HLM2

Modelo com Interceptos e Inclinações Aleatórios

Nível 1

$$desempenho_{ij} = \beta_{0j} + \beta_{1j} \cdot horas_{ij} + \varepsilon_{ij}$$

Nível 2

$$\begin{cases} \beta_{0j} = \gamma_{00} + v_{0j} \\ \beta_{1j} = \gamma_{10} + v_{1j} \end{cases}$$

Substituindo...

$$desempenho_{ij} = \gamma_{00} + \gamma_{10} \cdot horas_{ij} + v_{0j} + v_{1j} \cdot horas_{ij} + \varepsilon_{ij}$$

LINHA
415 DO
SCRIPT

Modelagem HLM2

Modelo Final HLM2

Nível 1

$$desempenho_{ij} = \beta_{0j} + \beta_{1j} \cdot horas_{ij} + \varepsilon_{ij}$$

Nível 2


$$\begin{cases} \beta_{0j} = \gamma_{00} + \gamma_{01} \cdot texp_j + v_{0j} \\ \beta_{1j} = \gamma_{10} + \gamma_{11} \cdot texp_j + v_{1j} \end{cases}$$

Substituindo...

$$desempenho_{ij} = \gamma_{00} + \gamma_{10} \cdot horas_{ij} + \gamma_{01} \cdot texp_j + \gamma_{11} \cdot texp_j \cdot horas_{ij} + v_{0j} + v_{1j} \cdot horas_{ij} + \varepsilon_{ij}$$

LINHA
511 DO
SCRIPT


HLM2 x OLS x OLS com Dummies





Modelagem HLM3 com Medidas Repetidas

Modelagem HLM3 com Medidas Repetidas



Modelagem HLM3 com Medidas Repetidas

Modelo Nulo

Nível 1

$$desempenho_{tjk} = \beta_{0jk} + \varepsilon_{tjk}$$

Nível 2

$$\beta_{0jk} = \gamma_{00k} + v_{0jk}$$

Nível 3

$$\gamma_{00k} = \delta_{000} + \tau_{00k}$$

Substituindo...

$$desempenho_{tjk} = \delta_{000} + v_{0jk} + \tau_{00k} + \varepsilon_{tjk}$$

LINHA 1159
DO SCRIPT

Modelagem HLM3 com Medidas Repetidas

Modelo de Tendência Linear com Interceptos e Inclinações Aleatórios (*Growth Model*)

Nível 1

$$desempenho_{tjk} = \beta_{0jk} + \beta_{1jk} \cdot mes_{jk} + \varepsilon_{tjk}$$

Nível 2

$$\begin{cases} \beta_{0jk} = \gamma_{00k} + \nu_{0jk} \\ \beta_{1jk} = \gamma_{10k} \end{cases}$$

Nível 3

$$\begin{cases} \gamma_{00k} = \delta_{000} + \tau_{00k} \\ \gamma_{10k} = \delta_{100} + \tau_{10k} \end{cases}$$

Substituindo...

$$desempenho_{tjk} = \delta_{000} + \delta_{100} \cdot mes_{jk} + \nu_{0jk} + \tau_{00k} + \tau_{10k} \cdot mes_{jk} + \varepsilon_{tjk}$$

Linha Dos Santos Magistral 267.843.20218
**LINHA 1246
DO SCRIPT**

Modelagem HLM3 com Medidas Repetidas

Modelo de Tendência Linear com Interceptos e Inclinações Aleatórios e as Variáveis *ativ* de Nível 2 e *texp* de Nível 3 (Modelo Final)

Nível 1

$$desempenho_{tjk} = \beta_{0jk} + \beta_{1jk} \cdot mes_{jk} + \varepsilon_{tjk}$$

Nível 2

$$\left\{ \begin{array}{l} \beta_{0jk} = \gamma_{00k} + v_{0jk} \\ \beta_{1jk} = \gamma_{10k} + \gamma_{11k} \cdot ativ_{jk} \end{array} \right.$$

Nível 3


$$\left\{ \begin{array}{l} \gamma_{00k} = \delta_{000} + \tau_{00k} \\ \gamma_{10k} = \delta_{100} + \delta_{101} \cdot texp_k + \tau_{10k} \\ \gamma_{11k} = \delta_{110} \end{array} \right.$$

Substituindo...

$$desempenho_{tjk} = \delta_{000} + \delta_{100} \cdot mes_{jk} + \delta_{110} \cdot ativ_{jk} \cdot mes_{jk} + \delta_{101} \cdot texp_k \cdot mes_{jk} + v_{0jk} + \tau_{00k} + \tau_{10k} \cdot mes_{jk} + \varepsilon_{tjk}$$

LINHA 1302
DO SCRIPT

HLM3 com Medidas Repetidas x OLS com Dummies






FINALIZANDO...

Reflexão Multinível

“Devemos expandir o círculo do nosso amor até que ele englobe todo o nosso bairro; do bairro, por sua vez, deve desdobrar-se para toda a cidade; da cidade para o estado, e assim, sucessivamente, até que o objeto do nosso amor inclua todo o universo.”



Mahatma Gandhi
(1869 – 1948)

Obrigado!

Prof. Dr. Luiz Paulo Fávero |



MBAUSP
ESALQ