

MBA EM **DATA SCIENCE**
E ANALYTICS

**Big Data e Deployment de
Modelos II**

Prof. Helder Prado Santos

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº
9610/98

O que é Big Data?



O que é Big Data?


Big Data refere-se a **conjuntos de dados** extremamente **grandes e complexos** que não podem ser facilmente processados ou gerenciados **com ferramentas de processamento de dados tradicionais**



Entendendo a escala dos dados na internet

Um zettabyte (ZB) equivale a **1.024 exabytes** no padrão binário.

1 exabyte equivale a **1.073.741.824** Gigabyte

Explosão de Dados no Mundo






Fonte: <https://www.domo.com/data-never-sleeps>


A Explosão de Dados na Era da Inteligência Artificial

- **O motor do crescimento:** O boom da Inteligência Artificial Generativa (LLMs) acelerou a criação de dados não estruturados e de dados sintéticos (dados gerados por IA para treinar outras IAs).
- **Custo de armazenamento:** Embora o volume cresça exponencialmente, o custo de armazenamento em nuvem (S3, Azure Blob, GCS) tornou viável guardar históricos infinitos.

Como lidar com dados?



Os 5V's do Big Data



Os 5V's do Big Data

- **Volume:** Refere-se à quantidade massiva de dados que é gerada continuamente
- **Velocidade:** Indica a rapidez com que os dados são gerados, processados e disponibilizados para análise.
- **Variedade:** Representa a diversidade de tipos de dados, como dados estruturados, não estruturados e semiestruturados
- **Veracidade:** Refere-se à confiabilidade e qualidade dos dados.
- **Valor:** Representa a capacidade de extrair informações úteis e insights significativos a partir dos dados.

Como começamos a lidar com os 5V's?



Larissa Dos Santos

42.400-719


Frameworks de Big Data

Hadoop Map Reduce e **Apache Spark** são duas tecnologias amplamente utilizadas no ecossistema de Big Data, e cada uma desempenha um papel específico para **lidar com os desafios associados aos 5V's** do Big Data

Hadoop Map Reduce e Apache Spark

Tanto **Hadoop** quanto **Spark** são projetados para funcionar **em ambientes distribuídos**, onde **clusters de computadores** são utilizados para **processar grandes** volumes de dados.


Cluster de Computadores




Características do Hadoop Map Reduce

- **Armazenamento Distribuído:** O Hadoop Distributed File System (HDFS) permite armazenar grandes volumes de dados de maneira distribuída em clusters de servidores.
- **Processamento Distribuído:** O MapReduce, modelo de programação do Hadoop, facilita o processamento paralelo de grandes conjuntos de dados, dividindo tarefas em diferentes nós do cluster.
- **Escalabilidade:** Hadoop é escalável horizontalmente, o que significa que você pode adicionar mais servidores conforme a necessidade para lidar com o aumento de volume de dados.

O processo do MapReduce no Hadoop



A arquitetura do Apache Spark



Componentes do Apache Spark


- **DAG (Directed Acyclic Graph):** Um DAG é uma representação gráfica das operações que serão realizadas no Spark. Ele descreve o fluxo de dados através de um conjunto de operações.
- **Características:**
 - ✓ **Direcionado:** As arestas têm direção, indicando a sequência de operações.
 - ✓ **Acíclico:** Não há ciclos; uma vez que os dados são processados, não voltam ao mesmo ponto.
- **Função:** O DAG permite que o Spark otimize a execução das operações, dividindo tarefas em estágios e permitindo o paralelismo.

Componentes do Apache Spark

- **RDD (Resilient Distributed Dataset):** Um RDD é a estrutura de dados fundamental do Spark, representando uma coleção distribuída de objetos imutáveis.
- **Características:**
 - ✓ **Resiliente:** Pode se recuperar de falhas, recomputando dados a partir de suas operações originais.
 - ✓ **Distribuído:** Os dados são armazenados em diferentes nós de um cluster, permitindo processamento paralelo.
 - ✓ **Imutável:** Uma vez criado, não pode ser alterado; novas transformações geram novos RDDs.
- **Operações:**
 - ✓ **Transformações:** Operações que produzem um novo RDD (ex.: map, filter).
 - ✓ **Ações:** Operações que retornam um valor ao driver (ex.: count, collect).

Exemplo de uma DAG e seus RDDs

▼ DAG Visualization



Características do Apache Spark

- **Processamento In-Memory:** Ao contrário do Hadoop, que grava dados no disco entre as etapas do processamento, o Spark realiza processamento em memória, o que acelera significativamente a execução de tarefas.
- **Suporte a Diversos Tipos de Dados:** Spark é eficaz no processamento de dados em diferentes formatos, como dados estruturados, como parquet, avro, orc, json, csv, entre muitos outros.
- **Pipelines de Dados Complexas:** Spark oferece APIs para construir pipelines de dados complexos, permitindo realizar tarefas sequenciais de transformação e análise de dados.

Características do Apache Spark

- **DataFrames e Spark SQL:** Spark utiliza DataFrames como principal estrutura de dados, organizados em formato tabular (linhas e colunas).
 - ✓ Permite operações de alto nível (select, filter, groupBy)
 - ✓ Integra com Spark SQL para consultas declarativas
 - ✓ Usa o Catalyst Optimizer para otimização automática

Características do Apache Spark

- **Machine Learning Integrado:** Possui uma biblioteca de machine learning (MLlib) integrada, facilitando a implementação de algoritmos de aprendizado de máquina em grandes conjuntos de dados.
- **Streaming:** Spark Streaming permite processamento em tempo real, sendo útil para lidar com a velocidade dos dados.

Principais tecnologias de Big data


PRINCIPAIS FRAMEWORKS E TECNOLOGIAS DE BIG DATA



Estratégias para lidar com Big Data




Arquiteturas de Big Data: a jornada do Data Warehouse ao Data Lakehouse



Fonte: <https://www.databricks.com>


Arquitetura Medalhão

Medallion Architecture in the Lakehouse



Fonte: <https://www.databricks.com>

Estratégia de Compressão de Dados




... Até **87%** de redução de tamanho

... Até **34x** mais rápido para carregar os dados

... Até **99%** de redução de custos

Estratégias para Particionamento dos Dados



Referências

1. CHAMBERS, B.; ZAHARIA, M. Spark: The Definitive Guide. [s.l.] “O’Reilly Media, Inc.”, 2018.
2. WHITE, T. Hadoop: The Definitive Guide. [s.l.] “O’Reilly Media, Inc.”, 2015.
3. Documentation | Apache Spark. Disponível em: <<https://spark.apache.org/documentation.html>>.
4. Hadoop – Apache Hadoop 3.2.2. Disponível em: <<https://hadoop.apache.org/docs/stable/>>.
5. Michael Armbrust, Reynold S Xin, Cheng Lian, Yin Huai, Davies Liu, Joseph K Bradley, Xiangrui Meng, Tomer Kaftan, Michael J Franklin, Ali Ghodsi, et al. 2015. Spark sql: Relational data processing in spark. In Proceedings of the 2015 ACM SIGMOD international conference on management of data. 1383–1394.

Obrigado!

Prof. Helder Prado Santos | [linkedin.com/in/helderprado](https://www.linkedin.com/in/helderprado)

MBA USP
ESALQ