

MBA EM
DATA SCIENCE

Coleta de Dados: Crawlers e Web Scraping

Prof. Guilherme Lima

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Larissa Dos Santos Magistral: 867.843.400-78

MBAUSP
ESALQ

X

Minhas redes

guilhermelimadev



guilherme-lima-developer



Web Scrapping

Extraindo informações de forma automatizada

Quando não há API ou acesso direto aos dados




01

Como o Scraping funciona?

Como o Scrapy FUNCIONA



CÓDIGO



SITE



HTML

Como o Scrapy FUNCIONA



Extrai os dados

Web Scrapping ≠ Hacking



Scrapping


É legal, desde que
seja ético e público



Hacking

1. Quebrar a segurança
2. Invadir um sistema
3. Explorar vulnerabilidades
4. Acesso não autorizado

A INTERNET



Qual o navegador que você usa?

Você acessa a internet
com quais dispositivos?



Sabe o que é mais curioso?



Curiosamente, **não há uma autoridade central com poder legal** que controle e organize toda a internet.

Ao contrário do que muitos imaginam

Diversas organizações, que surgiram de maneira espontânea e colaborativa ao longo dos anos, são responsáveis por administrar diferentes aspectos da rede.


IETF

W3C

ICANN

ISOC

ARIN



O que aconteceria,
se alguém não seguir aos
padrões publicados por
essas organizações?

Ignorar os padrões definidos
por essas organizações pode
resultar em problemas
— suas criações podem
simplesmente não funcionar
corretamente na internet.





Web scraping, na prática, é quando seu programa assume o papel de um navegador, acessando e interpretando sites automaticamente.

MAIS SOBRE A INTERNET

REDE

Fundamentos da
Conectividade

HTML

A Arquitetura das
Páginas Web

CSS

Estilizando a
Experiência Visual

JAVASCRIPT

Tornando a Web
Dinâmica

CLIENTE

O Ponto de Acesso
do Usuário

SERVIDOR

O Fornecedor de
Conteúdo

SOBRE A INTERNET

REDE

Fundamentos da
Conectividade

HTML

A Arquitetura das
Páginas Web

CSS

Estilizando a
Experiência Visual

JAVASCRIPT

Tornando a Web
Dinâmica

CLIENTE

O Ponto de Acesso
do Usuário

SERVIDOR

O Fornecedor de
Conteúdo

HTML

Linguagem usada para estruturar e organizar o conteúdo de páginas na web.

Ferramentas de Desenvolvedor (DevTools)



Ferramentas de Desenvolvedor (DevTools)

São um conjunto de recursos embutidos nos navegadores modernos que permitem inspecionar, editar e depurar páginas da web em tempo real.

Como acessar

The screenshot displays the Chrome DevTools Network tab. The top toolbar includes icons for recording, pausing, and filtering, along with checkboxes for 'Preserve log' and 'Disable cache', and a 'No throttling' dropdown. Below this is a filter bar with a 'Filter' input, an 'Invert' checkbox, and a 'More filters' dropdown. A row of category buttons (All, Fetch/XHR, Doc, CSS, JS, Font, Img, Media, Manifest, WS, Wasm, Other) is visible. A horizontal timeline at the top of the list shows a green bar for a request lasting approximately 40 ms. The list below shows a single entry named 'ferramentas-...' with a blue icon. The entry is selected, and the 'Headers' sub-tab is active. The 'General' section of the headers shows the following details:

Property	Value
Request URL:	https://guilhermeonrails.github.io/ferramentas-por-navegador/
Request Method:	GET
Status Code:	200 OK
Remote Address:	[2606:50c0:8001::153]:443
Referrer Policy:	strict-origin-when-cross-origin

The 'Response Headers' section is also visible but currently collapsed.

Request URL: <https://guilhermeonrails.github.io/ferramentas-por-navegador/>

A URL para a qual a solicitação foi enviada

Request Method: GET


O método HTTP usado

Status Code:  200 OK

O status da resposta



REGRAS





Protocolo

HTTP

Um protocolo que define as regras para troca de informações dentro do modelo **cliente-servidor** na web.



cliente-servidor

Um modelo de comunicação entre
dois lados

Resumindo

HTTP

Como elas se comunicam

Cliente-servidor

Como as partes se organizam.

HTTP



Client



Server

SOBRE A INTERNET

REDE

Fundamentos da
Conectividade

HTML

A Arquitetura das
Páginas Web

CSS

Estilizando a
Experiência Visual

JAVASCRIPT


Tornando a Web
Dinâmica

CLIENTE

O Ponto de Acesso
do Usuário

SERVIDOR

O Fornecedor de
Conteúdo




BeautifulSoup



Homenagem a um poema

Lewis Carroll



BeautifulSoup

Uma biblioteca do Python usada para analisar e extrair informações de arquivos HTML de forma simples.

- Ler páginas da web e extrair títulos, links, tabelas, etc.;
- Transformar o HTML em objetos Python navegáveis, facilitando buscas por tags, classes, IDs e conteúdos.



WEB e um quarto bagunçado

A web é desorganizada e imprevisível.

Um scraper pode falhar por **um simples erro de estrutura.**

Por isso, mais do que culpar o site, é essencial prever exceções e tornar seu código resistente a imprevistos.





Que tipo de erro,
Poderia
acontecer neste
código?




```
1 from bs4 import BeautifulSoup
2 import pandas as pd
3
4 url = "https://br.investing.com/currencies/"
5 response = requests.get(url)
```



Permissões e Ações Legais



LGPD não menciona explicitamente o termo **scraping**





De acordo com o artigo 7º, §3º da LGPD, o tratamento de dados pessoais cujo acesso é público deve considerar a finalidade, a boa-fé e o interesse público que justificaram sua disponibilização.

Uma história do mundo real

2010



Pete Warden



Toda historia aqui



200 milhões

[Toda historia aqui](#)

Nomes

Localizações

Amigos

Interesses

PARE COM ESSA ATIVIDADE!



Pete Warden

Big data? Posso pagar, dar um jeito.

Advogados?

Calma aí...

Três critérios precisam ser atendidos

Consentimento

Termos de Serviço de muitos sites proíbem especificamente o uso de scrapers.

Problemas físicos

Scrapers derrubarem um site ou limitarem sua capacidade de atender outros usuários

Intencionalidade

A real intenção do código, o que ele faz



Scraping na prática

Sugestões de Leituras/Referências

Mitchell, R. 2024. Web Scraping with Python (3ª ed.). Editora Novatec

O livro-referência do tema. Cobre exatamente a progressão da aula: requests, BeautifulSoup, navegação por árvore HTML, formulários/login e Selenium para conteúdo dinâmico. Inclui um capítulo forte sobre ética e legalidade do scraping.

[Automate the Boring Stuff with Python \(2ª ed.\) — Al Sweigart](#)

Ideal para o público iniciante da aula. Tem capítulos práticos sobre requisições web, parsing de HTML e automação de navegador, com leitura leve. (Disponível gratuitamente online em automatetheboringstuff.com.)

Gourley, D.; Totty, B.; Sayer, M.; Aggarwal, A.; Reddy, S. 2002. O'Reilly Media

Aprofunda o que a aula só tangencia: o protocolo HTTP por baixo do `requests.get()` — status codes, headers (como o HEAD do seu código), cookies, sessões e cache. Entender HTTP é o que separa quem "usa requests" de quem "domina coleta web".

Obrigado!

Prof. Guilherme Lima | <https://www.linkedin.com/in/guilherme-lima-developer/>

MBAUSP
ESALQ