

MBA EM
DATA SCIENCE

Árvores, Redes e Ensemble Models II – III

Prof.^a Dra. Valquíria Alencar

Larissa Dos Santos Magalhães 867.843.400-78

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Larissa Dos Santos Magistrali 867.843.400-78

Agenda

01.

Conceitos Fundamentais

O que são modelos de ensemble e por que combinar modelos?

02.

Técnicas de Ensemble

Voting, averaging, bagging, boosting e stacking

03.

Random Forest

Algoritmo para redução de variância

04.

Aplicação Prática

Treinamento de modelo com Random Forest

05.

XGBoost

Biblioteca para treinar ensembles de árvores com foco em performance

06.

Aplicação Prática

Treinamento de modelo com XGBoost

01

Por que combinar modelos?

Do modelo único ao poder do ensemble

Limitações de uma árvore individual

Overfitting

A árvore pode crescer demais e começar a **"decorar" os dados de treinamento**, em vez de aprender padrões gerais.

Sensibilidade a pequenas mudanças

Pequenas **alterações** no conjunto de treinamento podem gerar uma **árvore completamente diferente**.

Larissa Dos Santos Magistral 867.843.400-78

DE ONDE VÊM OS ERROS DE UM MODELO?

Trade-off viés-variância



Alto viés = previsões consistentes, mas fora do alvo

Alta variância = previsões espalhadas e inconsistentes

- **Modelos de alto viés** normalmente são muito **simplistas para capturar os padrões** verdadeiros dos dados. Eles ajustam mal o conjunto de treinamento, levando a uma baixa precisão de treinamento e teste.
- **Modelos de alta variância** são **excessivamente flexíveis** e se ajustam muito de perto aos dados de treinamento, incluindo o ruído. Eles **ajustam demais o conjunto de treinamento** e não conseguem generalizar para dados não vistos, levando ao overfitting e a **previsões com variabilidade** alta.


O QUE BUSCAMOS

Um equilíbrio entre viés e variância

Reduzir o viés tende a **aumentar a variância** — e vice-versa. Não dá para zerar os dois.

Buscamos o ponto de **equilíbrio**: nem simples demais, nem flexível demais.

Os ensembles nos ajudam a chegar **mais perto desse equilíbrio** do que um modelo isolado.



Como podemos melhorar isso?

Larissa Dos Santos Magalhães 11.843.400-78

Imagine que você precisa tomar uma decisão difícil. Em vez de pedir a opinião de uma só pessoa, você consulta várias. A decisão final é a **opinião da maioria**.


Esse é o princípio do ensemble: **combinar vários modelos fracos para criar um modelo forte**.

ANALOGIA


O júri

Um único jurado pode ter vieses ou cometer erros.

Quando 12 jurados votam, os erros individuais tendem a diminuir. O veredito coletivo é **mais confiável** do que a opinião de qualquer pessoa sozinha.



Veredito: 10 × 2



Combinar múltiplos modelos para obter uma predição mais **robusta** e **precisa**

DEFINIÇÃO

O que é ensemble?

Ensemble treina **múltiplos modelos** e **combina suas previsões** em uma única saída.

Modelos diferentes erram em pontos diferentes — ao fazer a média ou votação entre vários modelos, **os erros individuais tendem a se cancelar**.

02

Técnicas de ensemble

Explorando voting/averaging, bagging, boosting e stacking

Larissa Dos Santos Magalhães 867.843.400-78

Estratégias de ensemble learning

Voting / Averaging

É a forma mais simples de ensemble. Vários modelos são treinados de forma **independente** e suas previsões são combinadas. Em classificação, usa-se a **votação**; em regressão, a **média** das previsões.

Bagging

Treina vários modelos do **mesmo tipo** usando **diferentes amostras** do conjunto de treinamento. A combinação das previsões **reduz a variabilidade** e melhora a generalização.

Boosting

Treina modelos de forma **sequencial**, em que cada novo modelo busca **corrigir os erros** dos anteriores. Essa estratégia aumenta gradualmente o desempenho do modelo final.


Stacking

Combina diferentes modelos usando um **meta-modelo**, que aprende a melhor forma de **integrar as previsões** dos modelos base para obter uma resposta final mais precisa.


Larissa Dos Santos Magalhães

Tipos de ensembles

Ensembles Paralelos



Ensembles Sequenciais



—> Fluxo de dados / treinamento - - -> Dependência (usa informação do modelo anterior)

03


Voting e averaging

A forma mais simples de combinar modelos

Larissa Dos Santos Magalhães 867.843.400-78

Do voto individual à decisão final

Cada modelo vota em uma **classe** — a mais votada vence.



Da previsão individual à média final

Cada modelo prevê um **número** — a saída é a média das previsões.



Hard voting, soft voting e averaging

CLASSIFICAÇÃO

Hard voting

Cada modelo vota em uma classe; a mais votada vence.

Modelo A: Doença
Modelo B: Saudável
Modelo C: Doença
Resultado: Doença (2×1)

CLASSIFICAÇÃO

Soft voting

Faz a média das **probabilidades** de cada modelo. Mais preciso quando os modelos são bem calibrados.

$P(\text{Doença}): 0,9 \cdot 0,4 \cdot 0,7$
Média: 0,67 → Doença

REGRESSÃO

Averaging

A previsão final é a das previsões numéricas.

Modelo A: R\$ 320 mil
Modelo B: R\$ 290 mil
Modelo C: R\$ 350 mil
Média: R\$ 320 mil


04

Bagging

Reduzindo variância com amostragem

Larissa Dos Santos Magistrali 867.843.400-78

Bagging: Bootstrap Aggregating



O que é bootstrap? Amostragem **com reposição** : cada amostra tem o mesmo tamanho dos dados originais, mas ~63% dos registros são únicos e o restante se repete — gerando diversidade entre os modelos.

Amostragem com reposição

Dados originais



sorteia 10 vezes, **devolvendo o registro a cada sorteio**

Amostra bootstrap 1



■ repetidos (3 e 7) □ 2, 4, 6 e 8 ficaram de fora


Dentro e fora da amostra: o conceito OOB



Validação gratuita

As amostras OOB nunca foram vistas pelo modelo — servem como **conjunto de teste embutido**, sem separar dados de validação.

Agregação reduz variância



O bagging mantém o viés de cada modelo, mas **reduz drasticamente a variância** do conjunto.

05

Boosting


Aprendizado sequencial e correção de erros

Larissa Dos Santos Magistrali 867.843.400-78

Um modelo simples e seus erros




Cada modelo corrige o anterior



A previsão final é a **soma ponderada** de todos os modelos da sequência.

Como o erro vai diminuindo?



Queda rápida no início

Cada estimador ataca o resíduo do anterior — sobra cada vez menos para corrigir.

Depois, estabiliza

Com muitos estimadores, o ganho diminui — e o modelo pode passar a decorar ruído.

Freios do boosting


Learning rate e **early stopping** param o processo no ponto certo.

Learning rate: descendo a duna até o vale

De olhos vendados na duna, você sente a inclinação do chão — o **gradiente** dá a **direção** do passo; o **learning rate** dá o **tamanho** do passo. No boosting, **cada passo é uma nova árvore** — o learning rate controla o quanto ela contribui.


Nós enxergamos o vale todo; quem desce sente apenas a inclinação sob os pés.

Passos minúsculos




Seguro, mas **leva mais tempo** para chegar ao ponto mais baixo — **aprendizado lento e caro**.

Passos gigantes



Atravessa o fundo e para do outro lado — fica **oscilando** de um lado para o outro, sem descansar no ponto mais baixo.

Passos equilibrados



Desce com boa velocidade e **chega ao ponto mais baixo** sem ultrapassá-lo. É o que buscamos.

Repare nos passos minúsculos: perto do topo o gradiente é grande e você anda bastante; perto do fundo o terreno fica plano, o gradiente diminui e os passos **encurtam sozinhos**. O tamanho real da passada = **learning rate** (fixo) × **inclinação** naquele ponto.

Três gerações de boosting

AdaBoost

1995

Repondera as observações: **erros ganham mais peso** na próxima rodada.

Gradient Boosting

2001

Cada novo modelo ajusta diretamente o **resíduo** (gradiente da função de perda).

XGBoost

2014

Gradient boosting **otimizado**: regularização + engenharia de alto desempenho.

06

Stacking

Meta-aprendizado: modelos que aprendem a combinar modelos

Larissa Dos Santos Magistrali 867.843.400-78

Dois níveis de modelos

NÍVEL 0

Regressão logística

Árvore de decisão

KNN



previsões dos modelos base viram **features**



NÍVEL 1

Meta-modelo



Predição final

Meta-modelo sem vazamento de dados

O risco

Se o meta-modelo treina com previsões feitas **sobre os dados de treino dos modelos base**, recebe previsões otimistas demais.

Vazamento de dados → **ensemble superestimado**

A solução: out-of-fold

Validação cruzada: cada previsão que alimenta o meta-modelo vem de um **fold que o modelo base não viu** no treino.

treino

treino

prevê

treino

treino

07

Random Forest


Conhecendo o algoritmo

Larissa Dos Santos Magistrali 867.843.400-78

A dupla aleatoriedade do Random Forest

1 • LINHAS


Bootstrap de observações



Cada árvore treina em uma **amostra bootstrap** diferente das linhas.

2 • COLUNAS

Subconjunto de variáveis por split



Em cada divisão, só um **subconjunto aleatório de features** é candidato ao split.

Duas camadas de aleatoriedade → árvores **descorrelacionadas** → ensemble mais eficaz.

Bagging tradicional × Random Forest

Bagging tradicional

- Bootstrap apenas das **linhas**
- Cada split considera **todas as variáveis**
- Variáveis fortes dominam → árvores **correlacionadas**

Random Forest

- Bootstrap das linhas + **sorteio de variáveis por split**
- Árvores exploram **caminhos diferentes**
- Árvores **descorrelacionadas** → maior redução de variância

Larissa Dos Santos Magistral 861.843.400-18

Como funciona o Random Forest

- 1 Cria N amostras **bootstrap** dos dados
- 2 Em cada divisão, considera apenas um **subconjunto aleatório de variáveis**
- 3 Treina uma **árvore completa** (profunda) em cada amostra
- 4 **Agrega** as previsões de todas as árvores

Inovação-chave

O sorteio de variáveis em cada divisão **descorrelaciona as árvores**.

Árvores mais diversas produzem um ensemble mais eficaz na **redução de variância**.

Hiperparâmetros do Random Forest

n_estimators

Define o **número de árvores** que formarão a floresta. Mais árvores geralmente deixam a previsão mais estável, mas aumentam o tempo de treinamento e gasto computacional.

max_features

Define **quantas variáveis** serão consideradas como candidatas em **cada divisão da árvore**. Valores muito altos tornam as árvores mais parecidas; valores menores aumentam a variedade do conjunto.

max_depth

Define o **número máximo de níveis** de cada árvore. Árvores muito profundas podem memorizar os dados de treinamento. Árvores mais rasas são mais simples, mas podem deixar de capturar padrões importantes.

min_samples_split

Define o **número mínimo de observações** que um nó precisa ter para poder ser dividido. Valores maiores dificultam novas divisões e geram árvores mais simples. Valores menores permitem árvores mais detalhadas.

min_samples_leaf

Define o **número mínimo de observações** que uma folha final deve conter. Valores maiores produzem previsões mais gerais e estáveis. Valores muito pequenos podem gerar regras específicas demais.

bootstrap

Define se cada árvore será treinada com uma amostra aleatória dos dados, selecionada **com reposição**. Quando True, cada árvore recebe uma amostra diferente, aumentando a diversidade da floresta e caracterizando o mecanismo de bagging.



Da teoria ao código

Será que um ensemble com Random Forest consegue superar o resultado de uma árvore individual?

Larissa Dos Santos Magistrali 867.843.400-78

08

XGBoost

Conhecendo a biblioteca eXtreme Gradient Boosting

Larissa Dos Santos Magistrali 867.843.400-78

O que é o XGBoost



Search docs

Installation Guide
Building From Source
Get Started with XGBoost

/ XGBoost Documentation

[View page source](#)

XGBoost Documentation

XGBoost is an optimized distributed gradient boosting library designed to be highly **efficient**, **flexible** and **portable**. It implements machine learning algorithms under the [Gradient Boosting](#) framework. XGBoost provides a parallel tree boosting (also known as GBDT, GBM) that solve many data science problems in a fast and accurate way. The same code runs on major distributed environment (Hadoop, SGE, MPI) and can solve problems beyond billions of examples.

Biblioteca **otimizada e distribuída** de gradient boosting — eficiente e flexível.

Trata **valores faltantes** nativamente e **dispensa a dumalização** de variáveis categóricas.

Traz **regularização L1 e L2** embutida, controlando a complexidade das árvores e protegendo contra overfitting.

Escala para **grandes volumes de dados** em ambientes distribuídos (Ex: Hadoop).

A ideia central do XGBoost



Regularização L1/L2

$$\text{objetivo} = \text{erro nos dados} + \text{penalidade pela complexidade}$$

Cada folha tem um **peso (w)**, que indica o quanto ela influencia a previsão final. A **regularização** funciona como um “freio”, penalizando pesos muito altos. Assim, o modelo evita previsões exageradas sem evidência suficiente nos dados.

Regularização L1 reg_alpha

- Ajuda o modelo a se tornar mais simples ao **penalizar a soma** dos valores absolutos dos **pesos das folhas** das árvores.
- Algumas contribuições podem ser reduzidas até zero, fazendo com que o modelo **ignore padrões fracos, ruidosos ou pouco relevantes**.
- Assim, a L1 funciona como um **mecanismo de seleção e simplificação**, ajudando a **reduzir o overfitting**.

Regularização L2 reg_lambda

- **Penaliza pesos muito grandes** nas folhas das árvores, **reduzindo a influência excessiva** de qualquer parte específica do modelo.
- Diferente da L1, ela normalmente não zera contribuições, mas **suaviza os valores**, tornando o modelo mais estável e menos sensível a variações ou padrões extremos nos dados de treino.
- É uma das formas mais comuns de **controlar a complexidade** do modelo, pois **evita** que as árvores façam **correções exageradas** a cada etapa do boosting.

Hiperparâmetros do XGBoost

n_estimators

Número **máximo de árvores** construídas **em sequência**. Mais árvores permitem mais correções, mas aumentam o custo computacional

learning_rate

Controla o **peso** da **contribuição de cada nova árvore** para a previsão final. Um valor alto faz mudanças grandes; um valor baixo faz ajustes menores e mais cuidadosos.

max_depth

Define o **número máximo de níveis** de cada árvore. Árvores muito profundas podem memorizar os dados de treinamento. Árvores mais rasas são mais simples, mas podem deixar de capturar padrões importantes.

min_child_weight

Define a **quantidade mínima de informação** que deve existir em um **nó filho** para que uma divisão seja aceita. Valores maiores tornam o modelo mais conservador, criando árvores mais simples.

subsample

Define a **fração das observações** de treinamento usada para construir cada árvore. Valores menores que 1 adicionam aleatoriedade, reduzem a dependência de casos específicos e podem ajudar a controlar o overfitting.

colsample_bytree

Define a **fração das variáveis disponíveis** para **construir cada árvore**. Isso aumenta a diversidade entre as árvores. Valores menores podem reduzir overfitting, mas valores muito baixos podem impedir que o modelo encontre variáveis importantes.

reg_alpha / reg_lambda

Regularização L1 / L2. **Controla complexidade e overfitting**. **L1:** Valores maiores favorecem modelos mais simples e podem reduzir a influência de variáveis pouco relevantes. **L2:** Valores maiores tornam as previsões mais suaves e conservadoras, ajudando a reduzir o overfitting.

Modelo sensível a tuning

Use early stopping e validação cruzada para calibrar!



Da teoria ao código

Com Random Forest, alcançamos **83%** de recall e **96%** de acurácia.

Será que o XGBoost consegue superar esse resultado?

XGBoost em Python

```
from xgboost import XGBClassifier
xgb = XGBClassifier(
    n_estimators=300,
    learning_rate=0.1,
    max_depth=6,
    early_stopping_rounds=20)
xgb.fit(X_train, y_train,
        eval_set=[(X_val, y_val)])
y_pred = xgb.predict(X_test)
```

Interface familiar

Mesmo fit / predict do scikit-learn.

Early stopping

Para de adicionar árvores quando a validação para de melhorar.


Mesmas métricas

Acurácia, matriz de confusão, ROC (Classificação) MSE, RMSE, MAE (Regressão)

Decision Tree × Random Forest × XGBoost

CRITÉRIO	Decision Tree	Random Forest	XGBoost
Tipo	Modelo único	Ensemble bagging	Ensemble boosting
Treinamento	Construção recursiva da árvore, escolhendo o melhor split em cada nó	Paralelo	Sequencial, cada árvore corrige erros anteriores
Viés / variância	Baixo viés, alta variância	Reduz variância	Reduz principalmente viés; pode controlar variância com regularização
Overfitting	Alto risco	Menor risco que uma árvore única	Pode sofrer overfitting sem regularização/tuning
Interpretabilidade	Alta	Média/baixa, explicável por feature importance	Média/baixa, explicável por feature importance
Velocidade de treino	Rápida	Média a alta, mas paralelizável	Média; otimizada, mas sequencial <i>*Pode ser rápido na prática, mas depende bastante do volume de dados e dos hiperparâmetros.</i>
Sensível a hiperparâmetros	Pouco	Média	Muito

Do simples ao máximo desempenho





Sugestões de Leituras/Referências

Livro-base

- GÉRON, A. *Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow*. 2. ed. Rio de Janeiro: Alta Books, 2021.

Documentação técnica

- SCIKIT-LEARN. *Ensemble methods*. Disponível em: <https://scikit-learn.org/stable/modules/ensemble.html>
Referência oficial com a descrição dos estimadores usados nos notebooks: VotingClassifier, BaggingClassifier, RandomForestClassifier, GradientBoostingClassifier e StackingClassifier.
- XGBOOST DEVELOPERS. *XGBoost Documentation*. Disponível em: <https://xgboost.readthedocs.io/en/stable/>.
Documentação oficial do XGBoost.

Leitura complementar

- CHEN, T.; GUESTRIN, C. *XGBoost: A Scalable Tree Boosting System*. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, p. 785-794.
Disponível em: <https://arxiv.org/abs/1603.02754>. Artigo original do XGBoost. Leitura recomendada para entender as escolhas de projeto que tornaram o algoritmo padrão em competições e aplicações industriais.

Obrigada!

Prof.^a Dra. Valquíria Alencar | [linkedin.com/in/valquiria-alencar](https://www.linkedin.com/in/valquiria-alencar)

MBAUSP
ESALQ