

MBA EM
DATA SCIENCE

Árvores, Redes e Ensemble Models I

Prof.^a Dra. Valquíria Alencar

Larissa Dos Santos Magalhães 867.843.400-78

MBAUSP
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Larissa Dos Santos Magistrali 867.843.400-78

MBAUSP
ESALQ

Agenda

01. **Conceitos Fundamentais**
O que são e como funcionam as árvores de decisão?

02. **Aplicações Estratégicas**
Problemas reais e casos de uso

03. **Treinamento do Modelo**
Como a árvore aprende?

04. **Validação e Métricas**
Medindo desempenho e capacidade de generalização

05. **Desafios**
Overfitting e limitações comuns

06. **Hiperparâmetros**
Melhorando a performance do modelo

01

O que são e como funcionam as árvores de decisão?


Larissa Dos Santos Magalhães 867.843.400-78

Imagine que é uma sexta-feira à noite e você está decidindo se vai pedir delivery ou não




O que você pode levar em consideração para tomar essa decisão?

- Tenho comida em casa?
- Estou com vontade de cozinhar hoje?
- Estou cansado depois do trabalho?
- Estou com vontade de comer algo diferente?
- Quero gastar dinheiro com delivery?
- Tem promoção no aplicativo?



Conceitos Fundamentais

Estrutura de uma Árvore de Decisão



Nó Raiz (Root Node)

- O ponto de partida. Representa o conjunto de dados completo.

Nós Internos (Internal)

- Pontos da árvore onde são feitas perguntas sobre as características dos dados para definir o próximo caminho até a decisão final.

Folhas (Leaf Nodes)


- Resultados finais.

O que são Árvores de Decisão?

Definição

É um método de aprendizado de máquina **supervisionado não paramétrico** que faz **previsões dividindo os dados em etapas sucessivas**, como uma sequência de perguntas do tipo “verdadeiro ou falso”.

- modelo aprende com exemplos que já possuem a resposta
- adapta sua estrutura conforme aprende com os dados




Vantagens

Pouca Preparação dos Dados

As árvores de decisão exigem **menos tratamento** dos dados do que muitos outros algoritmos. Em diversos casos, não é necessário normalizar ou padronizar as variáveis.

Modelo White Box

Cada previsão pode ser explicada por uma **sequência clara de regras e condições**. Isso aumenta a confiança nos resultados e facilita sua comunicação.



Flexibilidade nos Tipos de Dados

Podem trabalhar com **variáveis numéricas e categóricas** simultaneamente. Isso amplia sua aplicação em diferentes problemas de negócio.

Robustez a Dados Reais

As árvores de decisão costumam apresentar bom desempenho **mesmo quando os dados não seguem padrões** estatísticos ideais.

02

Problemas reais e Casos de uso

Larissa Dos Santos Magalhães 867.843.400-78

Aplicações Práticas

Exemplos de onde as árvores de decisão podem ser usadas



Finanças e Crédito

Avaliação de risco de crédito e detecção de fraudes em transações bancárias.



Saúde e Medicina

Predição do risco de desenvolvimento de doenças, com base em sintomas e resultados de exames médicos.



Marketing e Negócios

Previsão de evasão (churn) e segmentação de clientes para campanhas personalizadas.



Educação

Identificação de alunos com risco de evasão com base em fatores como frequência, notas e participação nas atividades.

Exemplos reais

Article | [Open access](#) | Published: 09 March 2026

Interpretable machine learning based decision tree model for predicting obstructive airway disease in a large non-smoking health screening population

[Chih-Yueh Chang](#), [Hsiang-Shi Shen](#), [Yen-Liang Kuo](#), [Li-Na Lee](#), [Kuo-Ching Kao](#), [Tzu-Chi Liu](#) & [Chi-Jie Lu](#) ✉

[Scientific Reports](#) **16**, Article number: 12807 (2026) | [Cite this article](#)

2025 | OriginalPaper | Chapter

Decision Trees and Machine Learning for Cybersecurity: How Model Settings Affect Attack Detection

Authors: Konrad Lukiewicz, Michal Podpora, Grzegorz Dralus, Damian Mazur, Jakub Dralus, Tomasz Kajdanowicz, Aleksandra Kawala-Sterniuk

Published in: [Computational Science – ICCS 2025 Workshops](#)

Publisher: Springer Nature Switzerland

Article | [Open access](#) | Published: 12 May 2022

Decision tree based ensemble machine learning model for the prediction of Zika virus T-cell epitopes as potential vaccine candidates

[Syed Nisar Hussain Bukhari](#), [Julian Webber](#) & [Abolfazl Mehbodniya](#) ✉

[Scientific Reports](#) **12**, Article number: 7810 (2022) | [Cite this article](#)

5786 Accesses | **62** Citations | **2** Altmetric | [Metrics](#)

Article | [Open access](#) | Published: 27 November 2025

Analysis of factors affecting the academic performance of university students using machine learning

[Yuri Reina Marín](#), [Lenin Quiñones Huatangari](#), [Judith Nathaly Alva Tuesta](#), [Omer Cruz Caro](#) ✉, [Jorge Luis](#)

[Maicelo Guevara](#), [Einstein Sánchez Bardales](#) & [River Chávez Santos](#)

[Scientific Reports](#) **15**, Article number: 44027 (2025) | [Cite this article](#)

7214 Accesses | **4** Citations | [Metrics](#)

Classificação vs. Regressão

Qual é a diferença?

Árvores de Classificação

Usadas quando a variável que queremos **prever** é uma **categoria**.

A folha da árvore retorna a **classe mais frequente** dos dados que caíram nela.

*Cliente cancela ou continua?
Email é Spam ou Importante?*

Árvores de Regressão


Usadas quando a variável que queremos **prever** é um **número contínuo** ou **quantitativo discreto**.

A folha da árvore retorna a **média dos valores** dos dados que caíram nela.

*Qual o preço de venda desta casa?
Qual o tempo de entrega previsto?*


Exemplo de Classificação

Predição de risco de doença cardíaca



Exemplo de Regressão

Predição de preço de automóvel usado



03


Como a árvore aprende?

Larissa Dos Santos Magalhães 867.843.400-78

Treinamento

Por que precisamos treinar?

O modelo **aprende os padrões** usando os dados de Treino. Usamos os dados de Teste (que ele nunca viu) como uma "prova final" para medir sua capacidade de generalizar o aprendizado para o mundo real.



Separação dos dados em Treino e Teste



Garantindo que o modelo aprenda padrões e seja validado com dados novos.

Como as previsões são feitas em Classificação?

Exemplo: prever inadimplência

Base com 10 clientes:

- 5 adimplentes
- 5 inadimplentes.

Grupo inicial misturado – difícil decidir.

A árvore pergunta: tem atraso anterior?

Grupo 1 (com atraso): 4 inadimplentes, 1 adimplente

Grupo 2 (sem atraso): 4 adimplentes, 1 inadimplente

Agora os grupos ficaram mais organizados!

Em árvores de classificação, a melhor divisão é aquela que separa melhor as classes, reduzindo a impureza dentro dos grupos.

Como as previsões são feitas em Regressão?

Exemplo: prever preço de imóveis

Base com 6 imóveis:

- R\$ 200 mil
- R\$ 250 mil
- R\$ 300 mil
- R\$ 900 mil
- R\$ 1 milhão
- R\$ 1,1 milhão

Então a árvore testa uma pergunta: Área do imóvel > 100 m²?

Grupo 1 : 200, 250 e 300 mil

Grupo 2: 900 mil, 1 milhão e 1,1 milhão

Em regressão, a árvore não quer “separar classes”. Ela quer reduzir o erro entre o valor previsto e o valor real.

04

Medindo desempenho e capacidade de generalização

05

Classificação

Larissa Dos Santos Magistrali 867.843.400-78

Métricas de Avaliação

Classificação



Acurácia (Accuracy)

Mede a **proporção de acertos totais** do modelo.

Ou seja: de todas as previsões feitas, quantas estavam corretas.



Precisão (Precision)

Mede o quanto o **modelo "acerta"** quando diz que é **positivo**.

Crucial quando o custo de um erro de "falso alarme" é alto.



Sensibilidade (Recall)

Mede a capacidade do modelo de encontrar os **positivos reais**.

Importante quando perder casos positivos é crítico.



F1-Score

É a **média harmônica** entre precision e recall.

Muito usada em **bases desbalanceadas**, quando queremos equilibrar: evitar falsos positivos e negativos ao mesmo tempo.

Matriz de confusão

A base para o cálculo das principais métricas de avaliação de classificação

		Valor Predito 0	Valor Predito 1
Valor Real 0	VN	FP	
Valor Real 1	FN	VP	

Matriz de confusão

A base para o cálculo das principais métricas de avaliação de classificação

	Valor Predito 0	Valor Predito 1
Valor Real 0	VN	FP
Valor Real 1	FN	VP

Métricas

- **Acurácia:** $(VP+VN) / (VP+VN+FP+FN)$
- **Precisão:** $VP / (VP+FP)$
- **Recall:** $VP / (VP+FN)$
- **F1-Score:** $2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$

Exemplo: Análise de Crédito


	Valor Predito Bom pagador	Valor Predito Inadimplente
Valor Real Bom pagador	VN Acertou que o cliente honraria o pagamento.	FP Previu inadimplência para um bom pagador.
Valor Real Inadimplente	FN Concedeu crédito a quem não pagou.	VP Evitou prejuízo ao identificar o mau pagador.

Exemplo: Predição de Doença

	Valor Predito Baixo risco	Valor Predito Alto risco
Valor Real Baixo risco	VN Acertou que o paciente tem baixo risco de doença cardíaca.	FP Previu alto risco para uma pessoa de baixo risco.
Valor Real Alto risco	FN Previu baixo risco para uma pessoa de alto risco.	VP Acertou que o paciente tem alto risco de doença cardíaca.

Curva ROC

Capacidade do modelo em distinguir classes



Fonte: [Martin Thoma](#)

06

Regressão

Larissa Dos Santos Magistrali 867.843.400-78

Métricas de Avaliação


Regressão

2

MSE

Erro Quadrático Médio

- Média dos erros ao quadrado
- **Ideal:** quando erros grandes devem ser fortemente penalizados



RMSE

Raiz Quadrada do MSE

- **Ideal:** quando se deseja interpretar o erro na unidade original da variável



MAE

Erro Médio Absoluto

- Média das diferenças absolutas
- **Ideal:** quando se quer uma métrica robusta a outliers e fácil de interpretar



R^2 (R-Quadrado)

Coeficiente de Determinação

- Proporção da variância explicada pelo modelo.
- **Ideal:** quando se deseja avaliar a qualidade geral do ajuste

Métricas de Avaliação

Exemplo na predição de preço de imóveis

Imóvel	Valor real	Valor previsto	Erro	Erro absoluto
A	300	280	-20	20
B	500	550	-50	50
C	700	650	50	50
D	900	1.000	-100	100

Valores em mil reais.

Em média, o modelo erra R\$ 55 mil para mais ou para menos!

Métricas de Avaliação

Exemplo na predição de preço de imóveis

Imóvel	Valor real	Valor previsto	Erro	Erro ao quadrado
A	300	280	20	400
B	500	550	-50	2.500
C	700	650	50	2.500
D	900	1.000	-100	10.000

Valores em mil reais.

MSE = 3.850

RMSE = 62

O erro do modelo é de
aproximadamente R\$ 62 mil!

07

Validação Cruzada

Larissa Dos Santos Magistrali 867.843.400-78

Validação cruzada (K-fold)

Garantindo a robustez do modelo através de múltiplas partições dos dados



08

Overfitting e Limitações Comuns

Larissa Dos Santos Magalhães 867.843.400-78


Desvantagens

Overfitting

A árvore pode crescer demais e começar a **"decorar" os dados de treinamento**, em vez de aprender padrões gerais.

Desbalanceamento

Sensíveis a classes majoritárias, enviesando a divisão dos nós.



Sensibilidade a pequenas mudanças

Pequenas **alterações** no conjunto de treinamento podem gerar uma **árvore completamente diferente**.

Dificuldade de extrapolação

O modelo pode gerar previsões pouco realistas para valores fora da faixa dos dados de treinamento, pois tem **dificuldade em extrapolar** tendências de crescimento ou redução.

Overfitting

Entendendo o que é sobreajuste



O que é?

modelo **aprende** os dados de treinamento **de forma excessivamente detalhada**, capturando não apenas os padrões relevantes, mas também ruídos e particularidades que não representam o comportamento geral do problema.

Em vez de aprender regras que possam ser aplicadas a novos dados, o modelo acaba "decorando" os exemplos vistos durante o treinamento.

Causas

- Árvore muito profunda
- Muitas variáveis ou atributos irrelevantes
- Pouca quantidade de dados de treinamento

Como detectar?

A **acurácia** no conjunto de **treinamento é muito alta**, mas cai significativamente no conjunto de teste, mostrando que o modelo não consegue generalizar bem para dados que nunca viu.

09

Melhorando a Performance do Modelo

Larissa Dos Santos Magalhães 867.843.400-78

DecisionTreeClassifier

```
class sklearn.tree.DecisionTreeClassifier(*, criterion='gini',
splitter='best', max_depth=None, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_features=None, random_state=None,
max_leaf_nodes=None, min_impurity_decrease=0.0, class_weight=None,
ccp_alpha=0.0, monotonic_cst=None)
```

[\[source\]](#)

DecisionTreeRegressor

```
class sklearn.tree.DecisionTreeRegressor(*, criterion='squared_error',
splitter='best', max_depth=None, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_features=None, random_state=None,
max_leaf_nodes=None, min_impurity_decrease=0.0, ccp_alpha=0.0,
monotonic_cst=None)
```

[\[source\]](#)

Ajuste de Hiperparâmetros

Entendendo o que são hiperparâmetros e como ajustá-los

O que é?

São **configurações** definidas **antes do treinamento** do modelo. Elas **controlam como a árvore será construída** e influenciam diretamente sua capacidade de generalização.

Qual é o objetivo?

O objetivo é encontrar o equilíbrio entre:

- **Underfitting:** modelo muito simples, que aprende pouco.
- **Overfitting:** modelo muito complexo, que memoriza os dados de treino.

Boa generalização → desempenho consistente em novos dados.

Exemplos de hiperparâmetros

- **max_depth:** profundidade máxima da árvore.
- **min_samples_split:** mínimo de registros para dividir um nó.
- **min_samples_leaf:** mínimo de registros em uma folha.
- **criterion:** critério de divisão

Como encontrar os melhores valores?

1. Definir combinações de hiperparâmetros.
2. Treinar diferentes versões do modelo.
3. Avaliar o desempenho usando validação cruzada.
4. Selecionar a configuração com melhor resultado.



Sugestões de Leituras/Referências

Livro-base

- GÉRON, A. *Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow*. 2. ed. Rio de Janeiro: Alta Books, 2021.

Documentação técnica

- SCIKIT-LEARN. *Decision Trees*. Disponível em: <https://scikit-learn.org/stable/modules/tree.html>. Referência oficial da biblioteca, com explicação dos hiperparâmetros usados nos notebooks da disciplina.

Leitura complementar

- IBM. *What is bias-variance tradeoff?* Disponível em: <https://www.ibm.com/think/topics/bias-variance-tradeoff>. Texto curto e didático sobre o compromisso viés-variância, conceito central para entender por que ensembles funcionam.

Larissa Dos Santos Mestrado 867.811.400-78

Obrigada!

Prof.^a Dra. Valquíria Alencar | <https://www.linkedin.com/in/valquiria-alencar/>

MBAUSP
ESALQ